Projekt z przedmiotu
Eksploracja Danych

Zrozumienie problemu + Zrozumienie danych

Dane: Pokemon - Weedle's Cave

Autorzy: Jakub Nowak, Oliwier Komorowski, Piotr Staszko

Ogólny opis zbioru

- Zbiór zawiera statystyki Pokemonów oraz historyczne wyniki ich walk.
- Punkty danych opisują charakterystykę danego potwora: punkty zdrowia, siła ataku, obrona itd.
- Poddane analizie zostały dodatkowe pliki opisujące wygranych i przegranych.
- W symulacji uwzględniono ważną mechanikę walki: pierwszy wymieniony w zgłoszeniu Pokemon decyduje o pierwszym uderzeniu.

Cele eksploracji i kryteria sukcesu

- **Cel główny:** Predykcja wyników przyszłych walk Pokemonów na bazie statystyk. Docelowo jest to problem klasyfikacji binarnej (wygrana pierwszego organizmu: tak/nie).
- **Cel analityczny:** Określenie, które z atrybutów bojowych mają największy wpływ na wygraną walkę.
- **Miernik oceny:** Trafność (ang. Accuracy) badająca poprawność przypisania odpowiedniej klasy wygranej.
- **Kryterium sukcesu:** Osiągnięcie na testowym zbiorze dokładności rzędzu 85% lub więcej.

Struktura zbioru danych

- **Pochodzenie:** Platforma Kaggle (terminus7/pokemon-challenge), mechanika turowa z gier wideo.
- Rozmiar zbioru stanowi podział na 3 pliki:
  - `pokemon.csv` – 800 przykładów bazowych (12 atrybutów własnych potworów)
  - `combats.csv` – 50 000 historycznych wyników bitew ułatwiających wytrenowanie korelacji (3 atrybuty do parowania)
  - `tests.csv` – 10 000 par testowych dla domyślnej, nieznanej walidacji wyjściowej (2 atrybuty wprowadzające)

Atrybuty własne (pokemon.csv)

- **Identyfikujące:** `#` (ID), `Name` (nazwa gatunku).
- **Rodzaje / kategorie:** `Type 1`, `Type 2` (podstawowy i złożony żywioł determinujący słabości bazowe m.in. Ogień, Woda), flaga `Legendary` informująca o unikalnej rzadkości gatunku i przeważnie wrodzonych gigantycznych statystykach.
- **Współczynniki bitewne:** `HP` (punkty wytrzymałości życia), `Attack` (brutalna siła ciosu w zwarciu), `Defense` (odporność i gęstość pancerza na ataki zwarciowe).
- **Bitewne specjalne:** `Sp.Atk` oraz `Sp.Def` (odpowiedniki obrażeń i obrony na żywiołowe obrażenia dystansowe/magiczne).

Kluczowy atrybut taktyczny - Speed

- Atrybut **Speed** odgrywa kluczowe rozwiązanie w architekturze logiki turniejowej zaprezentowanego środowiska.
- Wyznacza on jednoznacznie inicjatywę tur i pierwszeństwo prewencyjnego uderzenia krytycznego.
- Oprócz ogólnych danych `combats.csv` posiada jedynie `First_pokemon` i `Second_pokemon`, po czym typuje docelowego zwycięzcę (`Winner`). Zjawisko przewagi na starcie będzie kluczem do predykcji przyszłych wyników.

Eksploracyjna Analiza (EDA) - Rozkłady

- Potwierdzono, że atrybuty bojowe na bazie próbek **nie posiadają rozkładu normalnego** - weryfikacja statystyczna Shapiro-Wilkiem wykazała wyniki $p < 0.05$.
- Posiadają one asymetrię - dominują wartości słabsze, natomiast zauważalny jest bardzo odległy ogon ("Elita Bossów").
- Rozkład w potyczkach turniejowych wygranej (`Winner`) jest bardzo dobrze obustronnie zbalansowany, co ułatwi trening klasyfikacyjny.
- Pod kątem kategoryzacji - w faunie wirtualnego gatunku dominują osobniki Wodne i Normalne.

EDA - Korelacje Spearmana

- Zaobserwowano silnie zgrupowane współzależności pomiędzy elementami siły potwora: `Attack`, `Defense`, `Sp.Atk`, `Sp.Def` korelują ze sobą. Rosną one wraz z doświadczeniem oraz elitarnością klasy gatunku (często w symbiozie).
- Zmiennymi najbardziej rzutującymi na Wygraną Walkę są połączone dyferencjały par (różnice w zestawianych mocach pomiędzy oboma oponentami).
- **Główne Odkrycie:** Najważniejszym wektorem odniesienia jest różnica `Diff_Speed` o potężnej korelacji. Na kolejnych stopniach podium ląduje `Diff_Attack` (brutalna moc destrukcji). Model defensywny i ukrywanie się za gęstym `Def` wygrywa walki zauważalnie rzadziej.

Analiza i jakość danych

- **Braki Danych:** Odnotowano pojedynczy brak nazwy Pokemona w 800 rekordach. Duża ilość pustych wartości w `Type 2` jest zaszłością w pełni naturalną i spójną (nie wszystkie potwory w tym świecie dysponują 2 zrzeszonymi typami magii). Należy zmapować je jako "None".
- **Outliery:** Wykazano kilka wartości odbiegających od norm (poza boxplot). Nie są to wartości zakropione błędem - odnoszą się one jedynie do potężnych, rzadkich organizmów i dodatnio i precyzyjnie wpłyną na poprawę wyników po nauczeniu.
- Wizualnie podsumowana jakość danych pozwala nam określić badany cel za perfekcyjnie wykonalny.

Wnioski końcowe

- Zrozumieliśmy biomechanikę uniwersum: Atakuje pierwszy i mocniej wygrywa chętniej.
- Prześwietlenie korelacji pozwala na potencjalną redukcję wymiarowości - możliwe, że do trafnej predykcji wystarczy zawęzić parametry do `Speed` i `Attack`, redukując nadmiarowe pokrewne atrybuty (jak warianty Specjalne lub proste warianty Defensywne).
- Dane są ustandaryzowane w stopniu dobrym, gotowe do połączenia tabel, rzutowania wyników starć oraz rozpoczęcia właściwej części projektowania algorytmu estymacyjnego.