Projekt z przedmiotu
Eksploracja Danych

Zrozumienie problemu + Zrozumienie danych

Dane: Pokemon - Weedle's Cave

Autorzy: Jakub Nowak, Oliwier Komorowski, Piotr Staszko

Ogólny opis zbioru

- Zbiór zawiera statystyki Pokemonów oraz historyczne wyniki ich walk.
- Punkty danych opisują charakterystykę danego pokemona: punkty zdrowia, siła ataku, obrona itd.
- Poddane analizie zostały dodatkowe pliki opisujące wygranych i przegranych.
- Mechanika walki: pierwszy wymieniony Pokemon atakuje jako pierwszy.

Cele eksploracji i kryteria sukcesu

- **Cel główny:** Predykcja wyników przyszłych walk Pokemonów na bazie statystyk.
- **Cel analityczny:** Określenie, które z atrybutów bojowych mają największy wpływ na wygraną walkę pokemona.
- **Miernik oceny:** Trafność (ang. Accuracy) badająca poprawność przypisania odpowiedniej klasy wygranej.
- **Kryterium sukcesu:** Osiągnięcie na testowym zbiorze dokładności rzędzu 85% lub więcej.

Struktura zbioru danych

- **Pochodzenie:** https://www.kaggle.com/datasets/terminus7/pokemon-challenge
- Rozmiar zbioru stanowi podział na 3 pliki:
  - `pokemon.csv` – 800 przykładów bazowych (12 atrybutów własnych pokemonów)
  - `combats.csv` – 50 000 historycznych wyników bitew
  - `tests.csv` – 10 000 par testowych bez wyniku walki

Atrybuty (pokemon.csv)

- **Atrybuty nominalne:** `#` - ID, `Name` - nazwa Pokemona, `Type 1` i `Type 2` - typy żywiołów.
- **Atrybuty numeryczne:** `HP`, `Attack`, `Defense`, `Sp.Atk`, `Sp.Def`, `Speed` - statystyki bojowe mierzone w punktach.
- **Wartości specjalne:** `Legendary` jest atrybutem binarnym i przyjmuje tylko wartości `0` lub `1`.

Wyniki EDA - Rozkłady i wstępne ustalenia

- **Rozkłady wartości atrybutów numerycznych** (`HP`, `Attack`, `Defense`, `Sp.Atk`, `Sp.Def`, `Speed`) są asymetryczne i odbiegają od normalności;
- W histogramach widoczna jest przewaga niższych i średnich wartości oraz długi prawy ogon (reprezentujący nieliczne, bardzo silne jednostki).
- **Rozkłady atrybutów nominalnych** pokazują, że najczęściej występują typy Wodne i Normalne.
- **Wstępne ustalenie dotyczące zawartości zbioru:** dane mają wystarczającą zmienność i strukturę, aby przejść do analizy zależności (korelacje).

Wykres: Histogramy statystyk bojowych

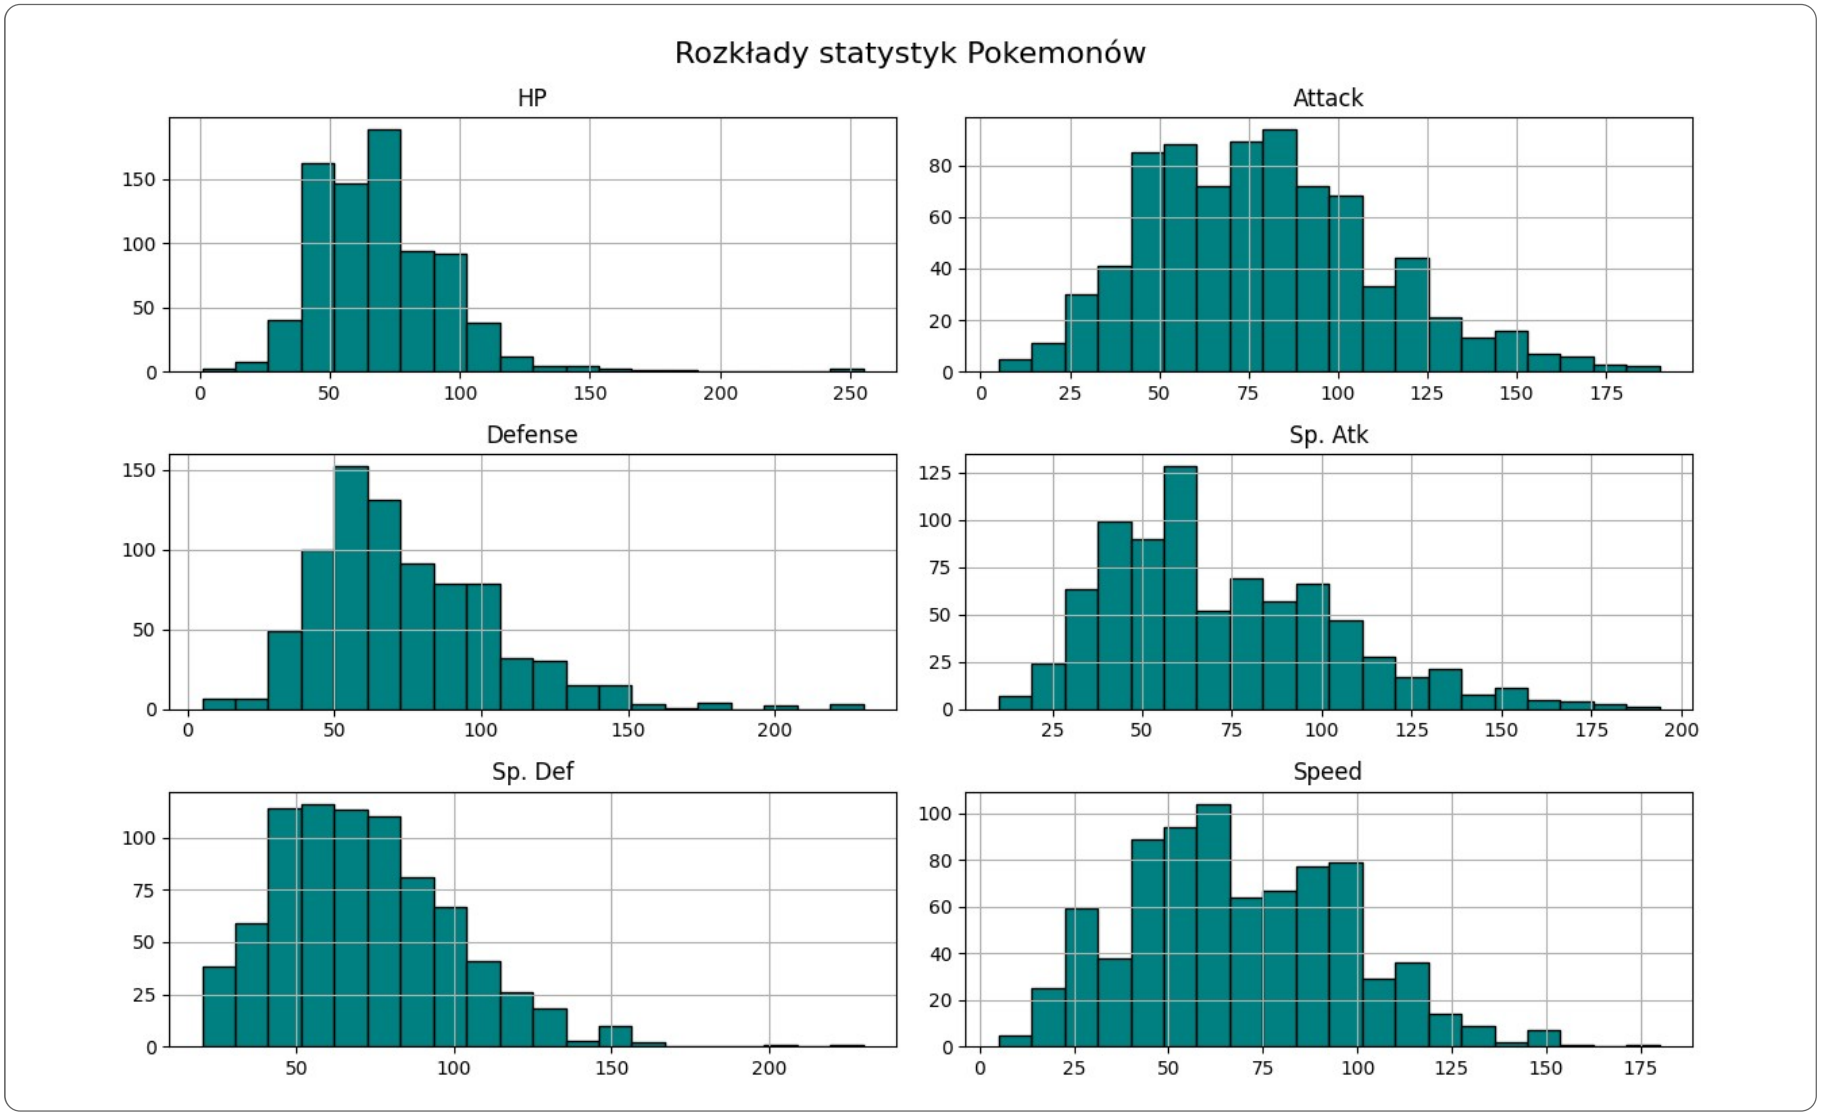

Histogramy statystyk bojowych

Wykres: Rozkład typów Pokemonów

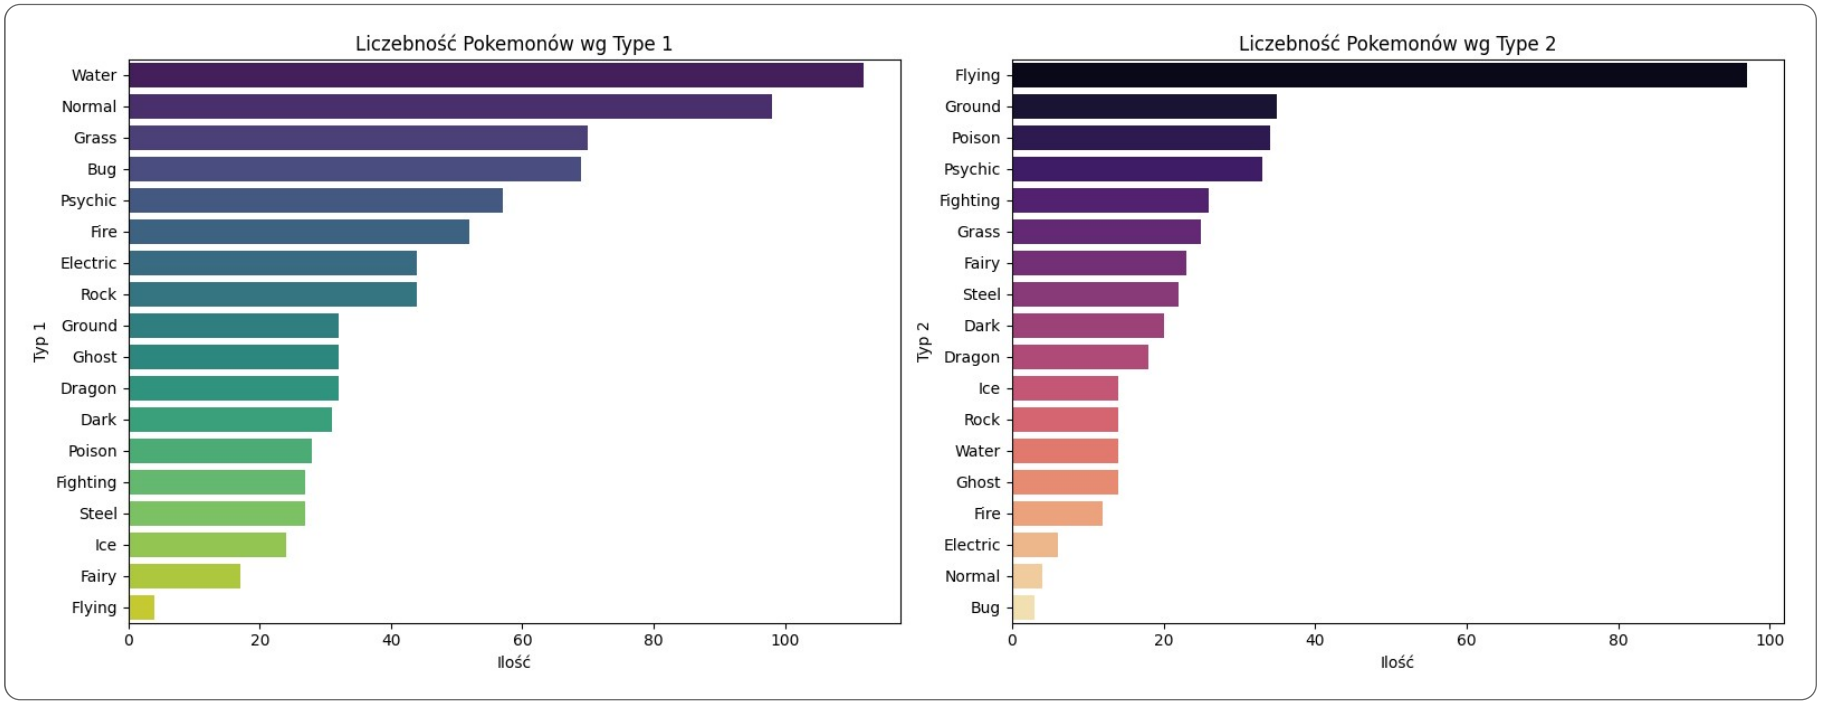

EDA - Korelacje Spearmana

- Zaobserwowano silnie zgrupowane współzależności pomiędzy elementami siły potwora: `Attack`, `Defense`, `Sp.Atk`, `Sp.Def` korelują ze sobą.
- O wyniku walki najlepiej informują cechy wyrażone jako różnice między statystykami Pokemonów.
- **Główne Odkrycie:** Najważniejszym wektorem odniesienia jest różnica `Diff_Speed` o potężnej korelacji. Na kolejnych stopniach podium ląduje `Diff_Attack` oraz 'Diff_Sp.Atk', co sugeruje, że przewaga w szybkości i ataku jest kluczowa dla zwycięstwa.

Wykres: Macierz korelacji Spearmana

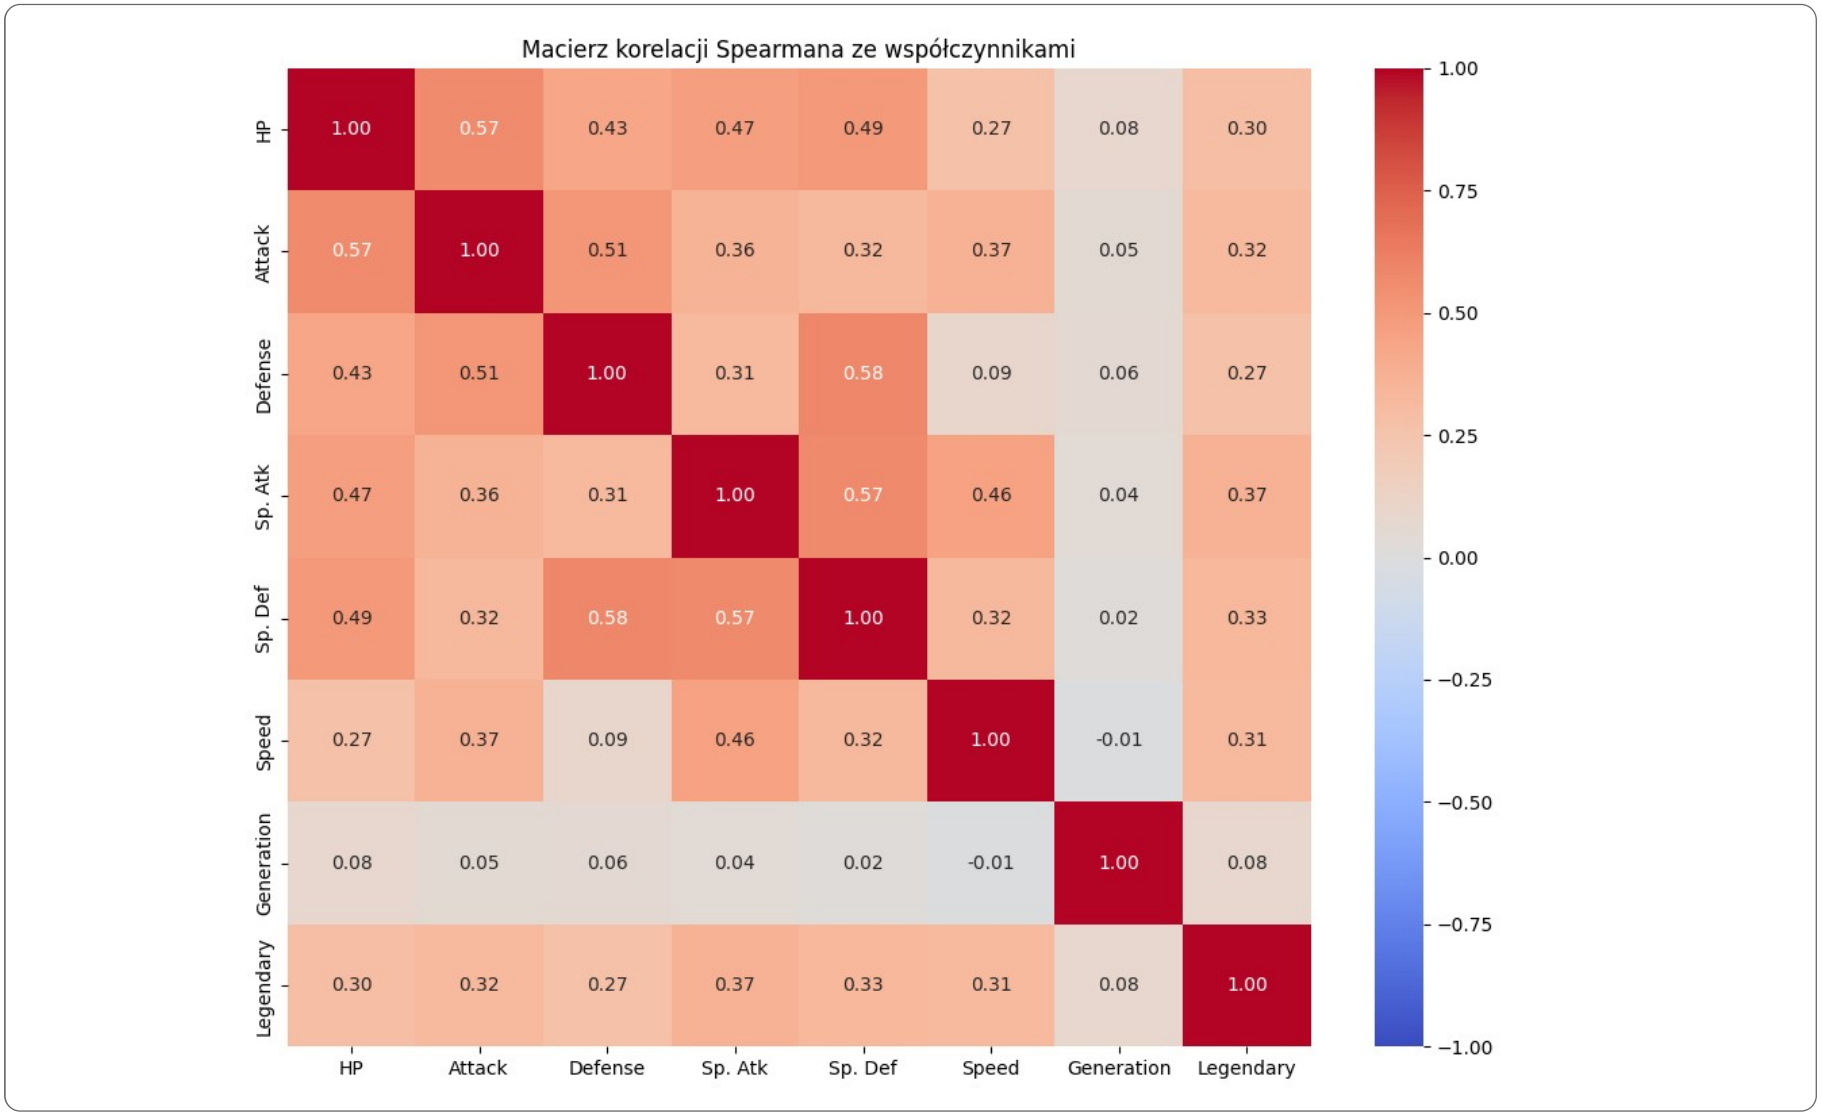

Macierz korelacji Spearmana

Wykres: Wpływ cech na wynik walki

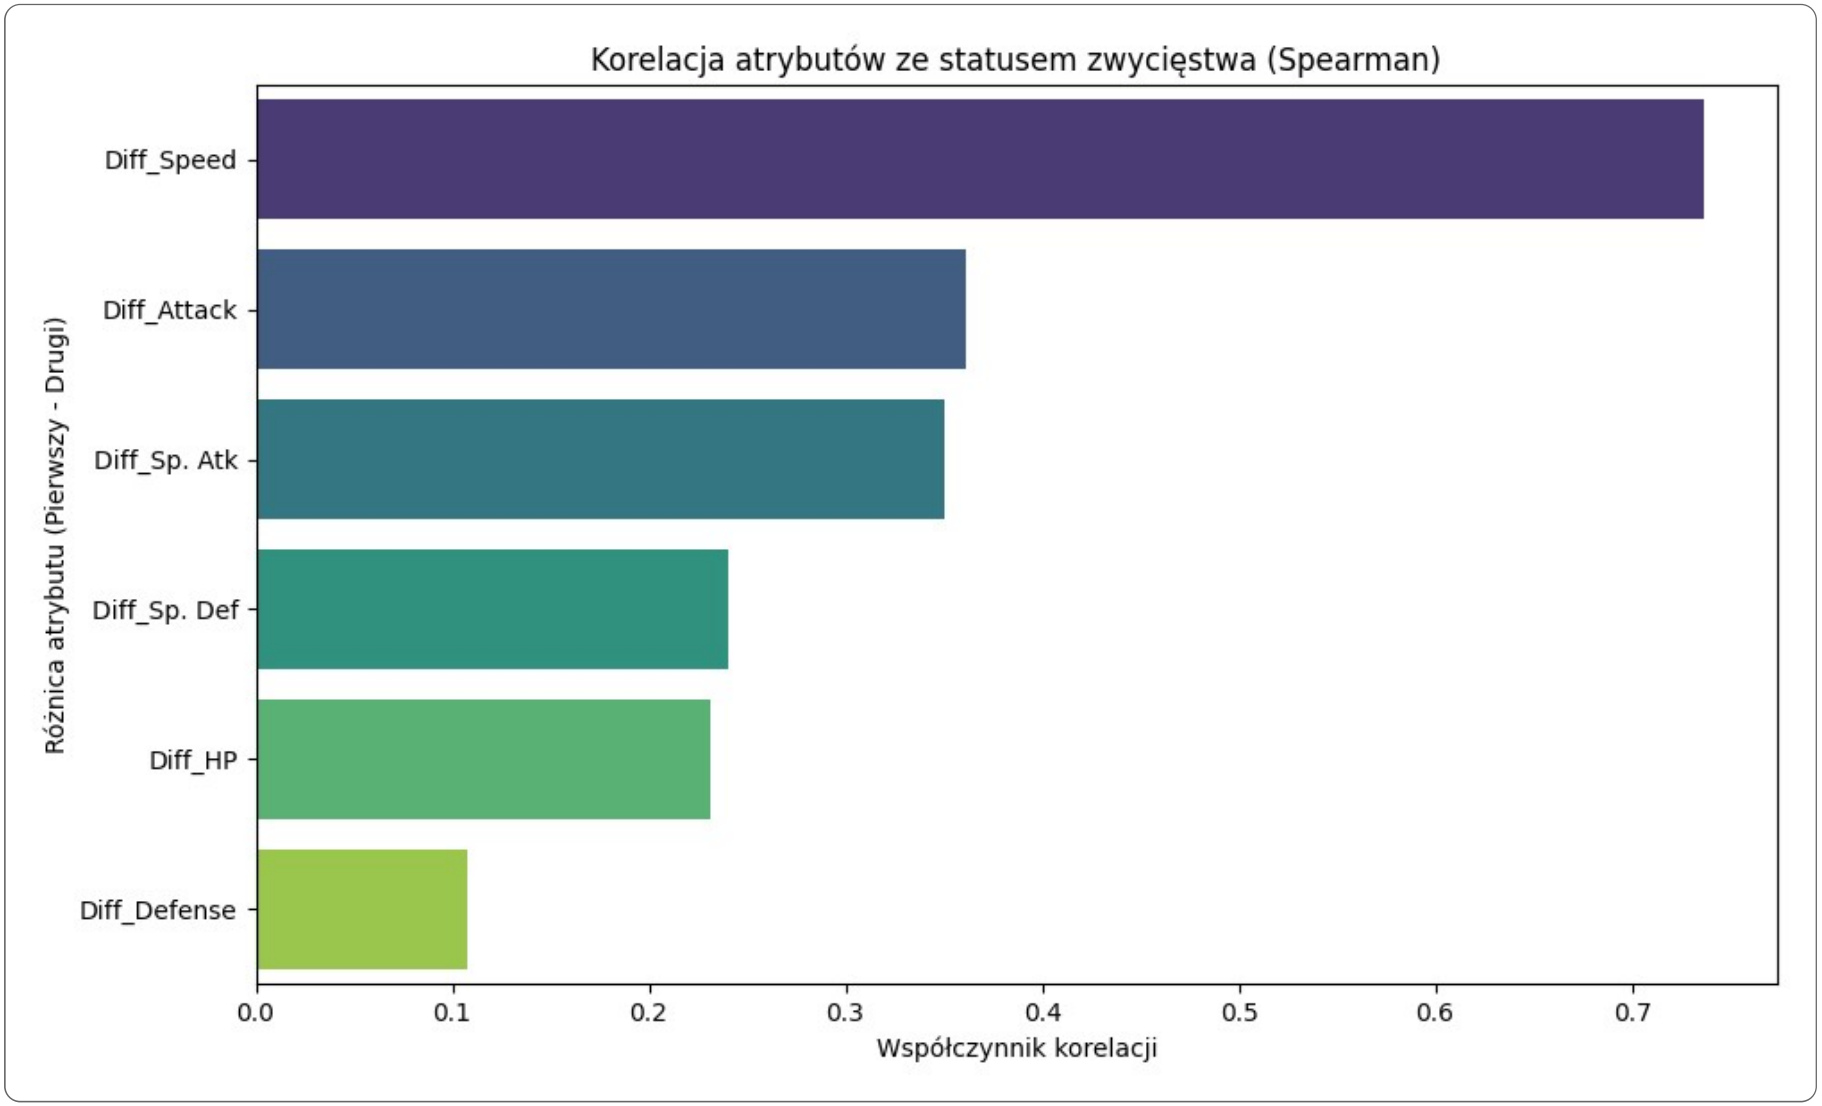

Wpływ cech na wynik walki

Analiza i jakość danych

- **Braki Danych:** Odnotowano pojedynczy brak nazwy Pokemona. Duża ilość pustych wartości w `Type 2` jest efektem w pełni naturalnym, natomiast należało by zmapować je jako "None".
- **Outliery:** Wykazano kilka wartości odbiegających od norm (poza boxplot). Nie są to wartości błędne - odnoszą się one jedynie do potężnych Pokemonów.
- Wizualnie podsumowana jakość danych pozwala nam określić badany cel za wykonalny.

Wykres: Outliery w atrybucie Attack

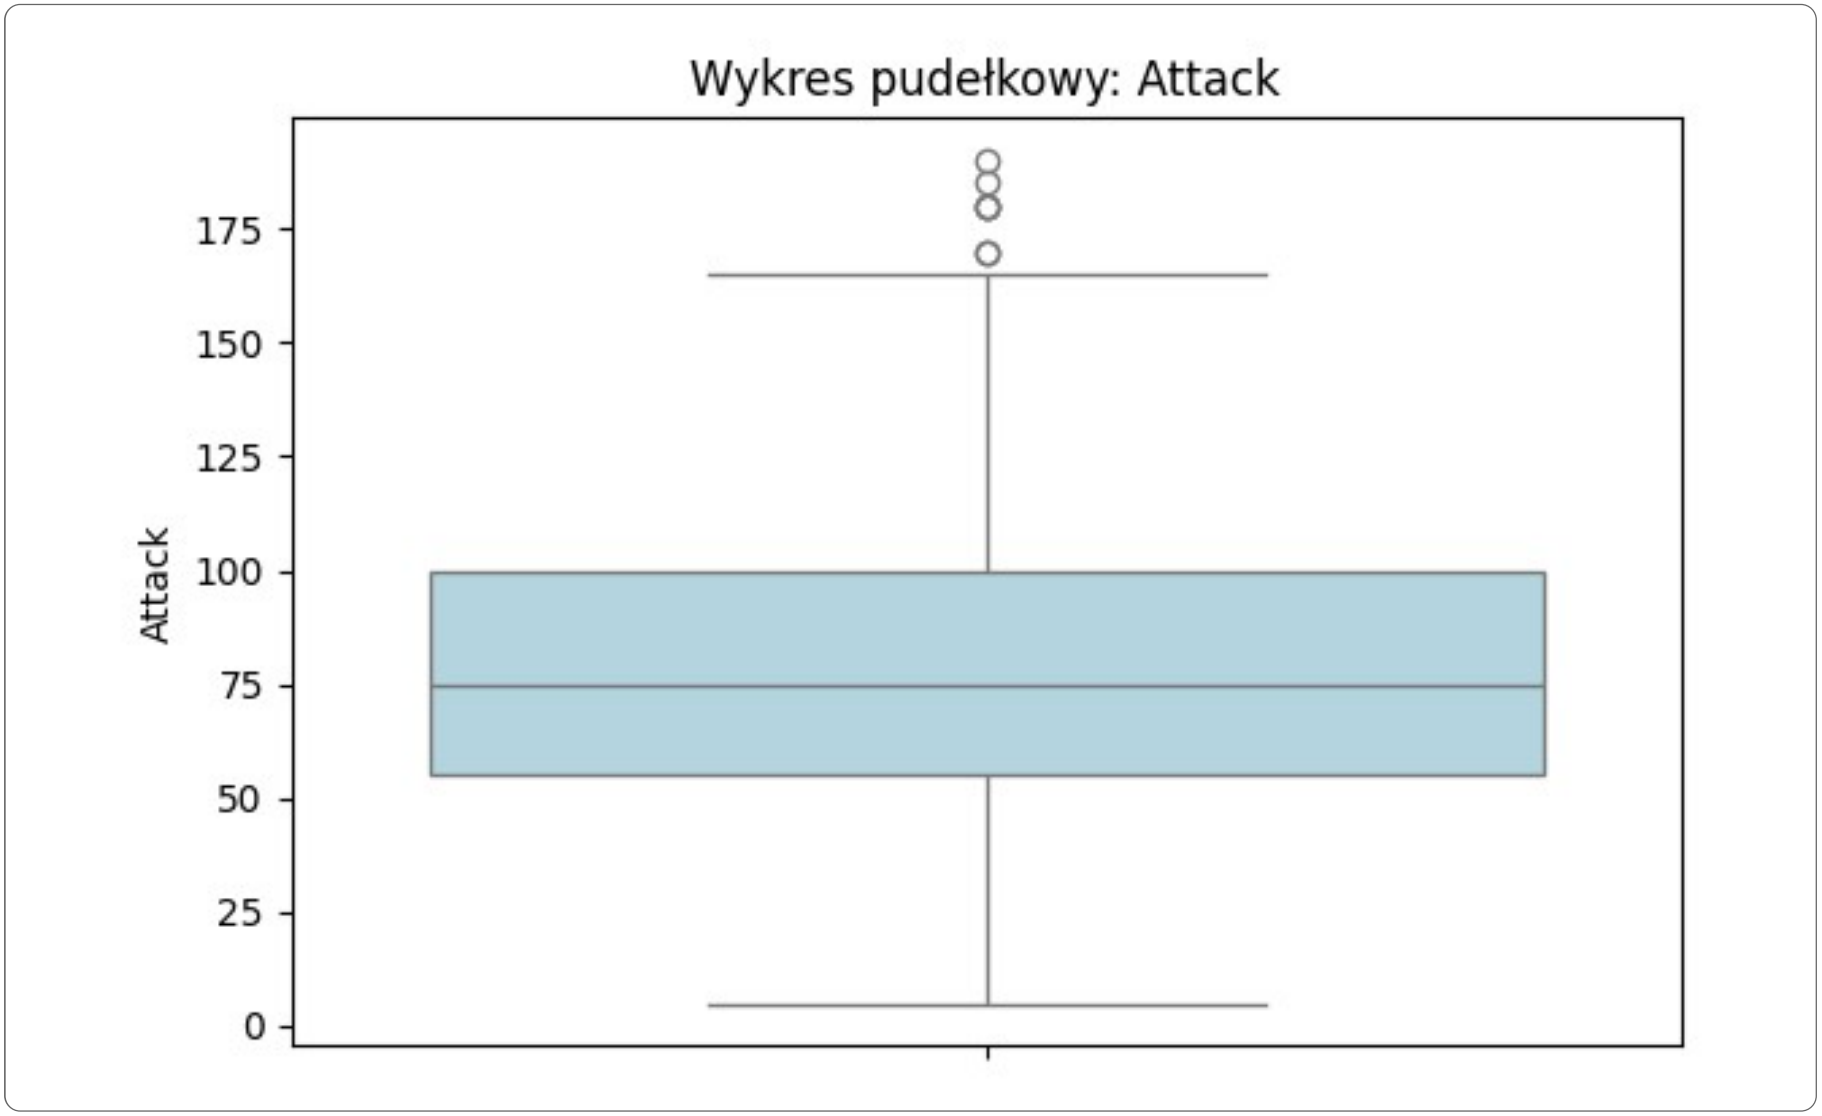

Outliery w atrybucie Attack (boxplot)

Wnioski końcowe

- Największy wpływ na wynik walki mają różnice w parametrach bojowych między dwoma Pokemonami, a nie pojedyncze wartości cech rozpatrywane osobno.
- Analiza korelacji pokazuje, że część atrybutów jest ze sobą silnie powiązana, więc do dalszego modelowania można rozważyć ograniczenie liczby powtarzających się cech.
- Dane są wystarczająco kompletne i spójne, aby przejść do etapu przygotowania modelu klasyfikacyjnego.