Projekt z przedmiotu Eksploracja Danych

Pierwszy etap: Zrozumienie problemu + Zrozumienie danych

Dane: Pokemon - Weedle's Cave
Autorzy: Jakub Nowak 197860 , Oliwier Komorowski 197808, Piotr Staszko 197938

Ogólny opis zbioru

Zbiór danych zawiera statystyki Pokemonów oraz historyczne wyniki ich walk. Każdy z rekordów w podstawowym pliku opisuje charakterystykę danego Pokemona (punkty zdrowia, punkty ataku, obrony, itd.). Dodatkowe pliki opisują rezultaty stoczonych potyczek między poszczególnymi Pokemonami. Należy uwzględnić dodatkowy wpływ mechaniki opisanej w źródle – pierwszy podany w walce Pokemon atakuje pierwszy.

Określenie celu eksploracji i kryteriów sukcesu

Celem eksploracji jest predykcja wyników przyszłych walk Pokemonów na bazie ich charakterystyki oraz historii poprzednich starć. Docelowo rozwiązywanym problemem będzie klasyfikacja binarna (przewidywanie, czy wygra pierwszy z walczących Pokemonów). Dodatkowym celem jest określenie, które atrybuty mają największy wpływ na predykcję wygranej.

W przypadku danego problemu istotną metryką będzie trafność (ang. *accuracy*), która informuje o tym, jak dobrze model ogólnie klasyfikuje zwycięzcę. Chcielibyśmy, aby nasz model poprawnie wyznaczał zwycięzcę dla jak największej liczby walczących par. Trafność jest metryką o poniższym wzorze:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

gdzie: TP (z ang. *true positive*) - liczba przypadków prawdziwie pozytywnych FN (z ang. *false negative*) - liczba przypadków fałszywie negatywnych TN (z ang. *true negative*) - liczba przypadków prawdziwie negatywnych FP (z ang. *false positive*) - liczba przypadków fałszywie pozytywnych

Ponieważ obie klasy (wygrana pierwszego Pokemona lub wygrana drugiego Pokemona) są naturalnie dystrybuowane, a błąd w dowolną stronę niesie ze sobą te same konsekwencje (w przeciwieństwie np. do diagnozy nowotworu medycznego), wykorzystanie trafności jest w tym przypadku miarą idealną i samowystarczalną. Sukces zostanie osiągnięty, jeżeli model uzyska trafność na poziomie powyżej 85%.

Charakterystyka zbioru danych

- **Pochodzenie:** Platforma Kaggle (dataset: *terminus7/pokemon-challenge*). Wynika z bazy gier "Pokemon", przy czym dane o samych walkach zostały wygenerowane algorytmicznie.
- **Format i struktura:** Zbiór jest dostarczony w postaci 3 plików CSV umieszczonych w folderze `dataset/`.
- **Rozmiar:**
  - `pokemon.csv` – 800 przykładów (statystyki Pokemonów) i 12 atrybutów.
  - `combats.csv` – 50 000 przykładów (wyniki wcześniejszych walk) i 3 atrybuty.

- `tests.csv` – 10 000 przykładów (zbiór, na którym model ma finalnie przewidzieć walki) i 2 atrybuty.

Opis atrybutów

W ogólności w tym zbiorze danych informacje podzielone są na dwa główne bloki tematyczne, w związku z czym atrybuty odwołują się do dwóch różniących się kategorii:

- **Cechy własne (pokemon.csv)**: definiują statystyki bazowe oraz przypisane typy poszczególnych Pokemonów.
- **Wyniki starć (combats.csv / tests.csv)**: definiują identyfikatory historycznych potyczek oraz informację o zwycięzcy.

Poniżej zamieszczono opis poszczególnych atrybutów zarówno numerycznych, jak i nominalnych. Atrybuty numeryczne w głównej mierze opisane zostały w odniesieniu do pojedynczego organizmu Pokemona (jego poszczególne statystyki przetrwania i ataku). Dokładne jednostki miary danych atrybutów liczbowych niestety nie zostały podane przez twórców zbioru danych - pochodzą one z empirycznej mechaniki cyfrowego środowiska gry wideo, więc nie odpowiadają rzeczywistym fizycznym jednostkom i należy je uznać za całkowicie względne wartości punktowe (tzw. *points*).

Plik pokemon.csv

Nazwa	Typ	Znaczenie
`#`	Numeryczny	Unikalny identyfikator reprezentujący danego Pokemona.
`Name`	Nominalny	Atrybut przechowujący nazwę rozpoznawczą gatunku Pokemona.
`Type 1`	Nominalny	Podstawowy typ/żywioł Pokemona (np. Grass, Fire). Wpływa on na mnożniki odporności i wrażliwości w walkach z innymi monstrami. W grze występuje 18 unikalnych klas tego atrybutu.
`Type 2`	Nominalny	Dodatkowy typ/żywioł Pokemona krzyżujący odporności u rzadszych osobników. Atrybut ten może być pusty, co oznacza brak hybrydowości organizmu pierwszego typu.
`HP`	Numeryczny	Atrybut informuje o puli punktów zdrowia Pokemona. Determinuje on ilość obrażeń, które Pokemon może otrzymać przed porażką.
`Attack`	Numeryczny	Parametr określający siłę uderzenia.
`Defense`	Numeryczny	Atrybut reprezentujący obronę przed atakami fizycznymi.
`Sp. Atk`	Numeryczny	Wartość określająca siłę ataków specjalnych , które pomijają standardową obronę fizyczną przeciwnika.
`Sp. Def`	Numeryczny	Statystyka oznaczająca odpowiedź na `Sp. Atk`. Powala zredukować lub uodpornić na wymianę i efekty ataków specjalnych.
`Speed`	Numeryczny	Istotny atrybut informujący o priorytetach uderzeń.
`Generation`	Numeryczny	Parametr generacji wyznaczający edycję gry w jakiej zaimplementowany został Pokemon. Przyjmuje ramy dyskretne: zbiór liczbowy 1-6.

Nazwa	Typ	Znaczenie
`Legendary`	Nominalny / Logiczny	Flaga atrybutu informująca, czy dany Pokemon zalicza się do rzadkich gatunków legendarnych. Pokemony z wartością 'True' charakteryzują się zazwyczaj znacznie wyższymi wartościami podstawowych statystyk i stanowią najsilniejszą grupę w grze.

Pliki combats.csv / tests.csv

Nazwa	Typ	Znaczenie
`First_pokemon`	Numeryczny	Identifier pierwszego walczącego Pokemona, pobierający z bazy wariant uderzający zawsze jako pierwszy na wejściu.
`Second_pokemon`	Numeryczny	Identifier drugiego walczącego, defensywnego na wejściu Pokemona.
`Winner`	Numeryczny	Zmienna celu wskazująca po identyfikatorze ostatecznego wygranego starcia pomiędzy podaną w zbiorze parą. (Obecna tylko w pliku combats.csv).

Wyniki eksploracyjnej analizy danych (EDA)

1. **Rozkłady wartości atrybutów**

Atrybut	Histogram
HP	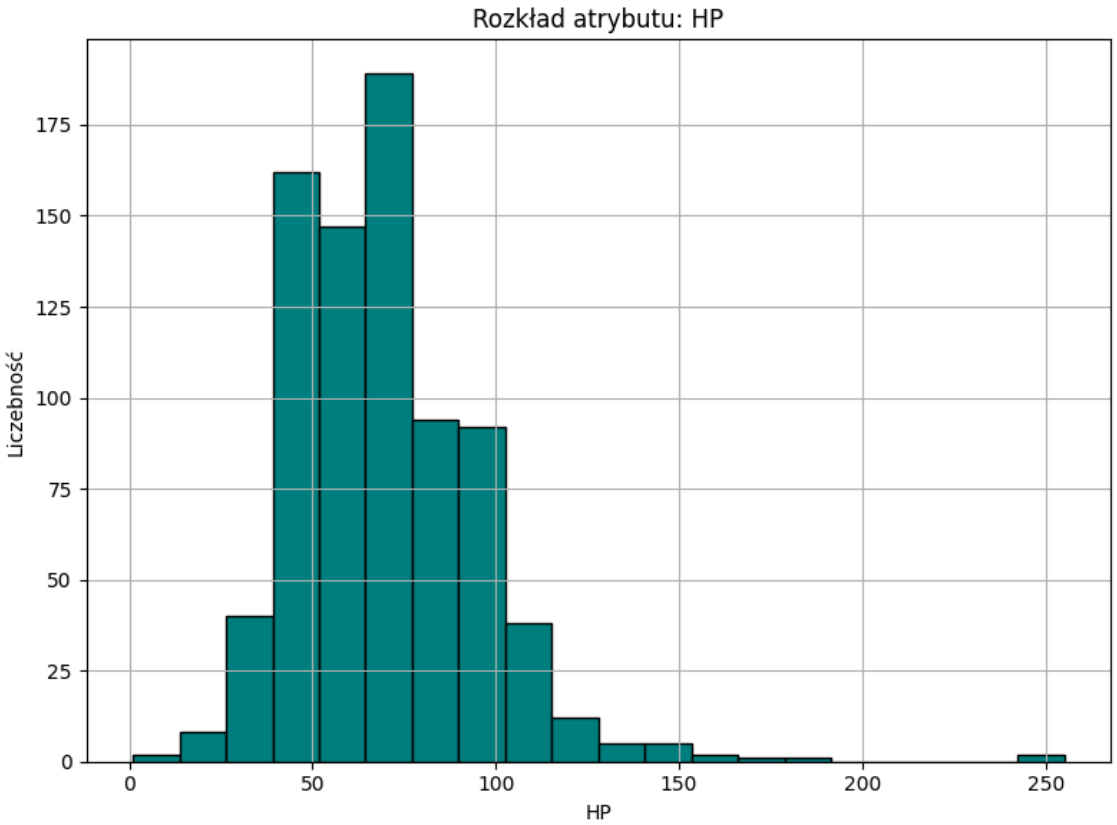

Atrybut	Histogram
Attack	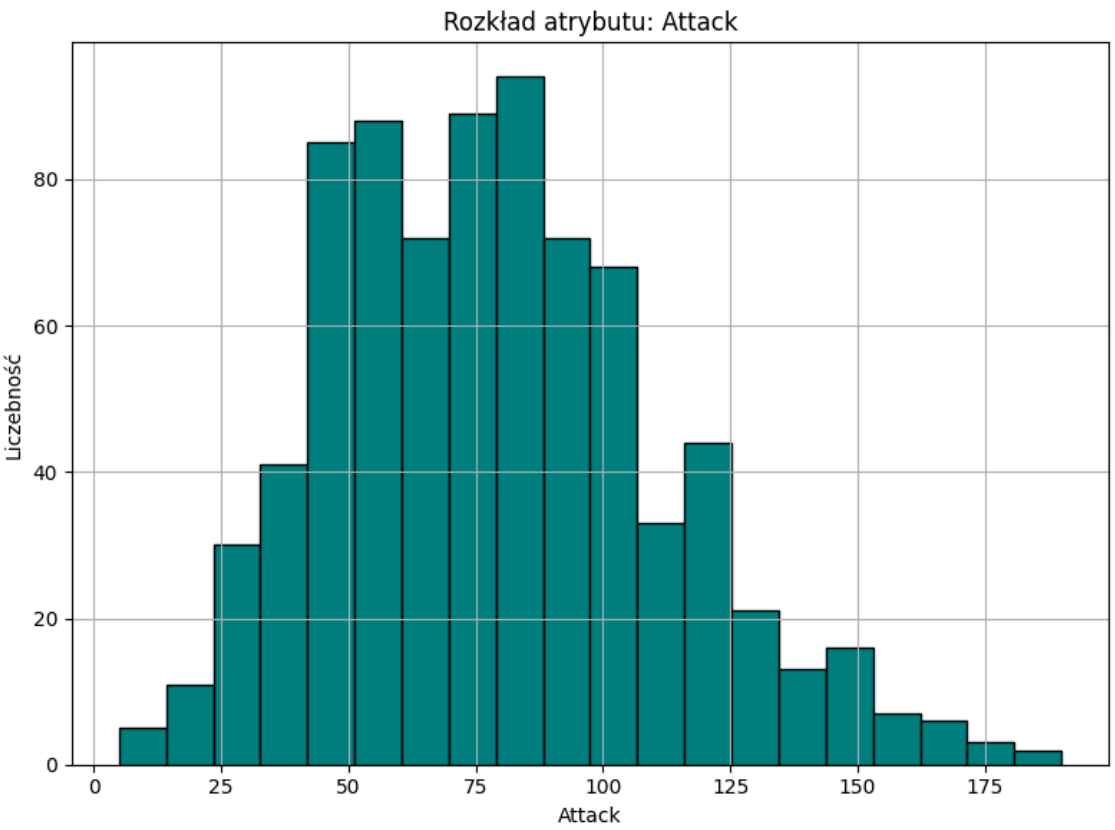
Defense	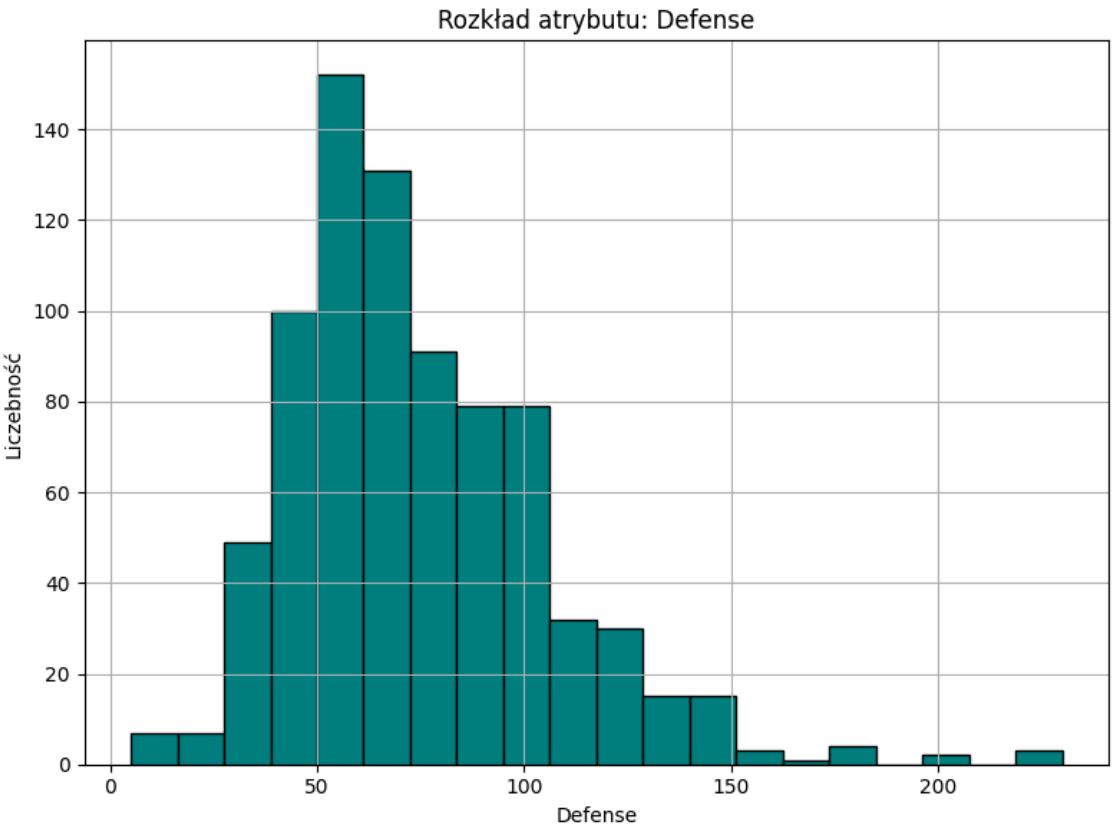

Atrybut	Histogram
Sp. Atk	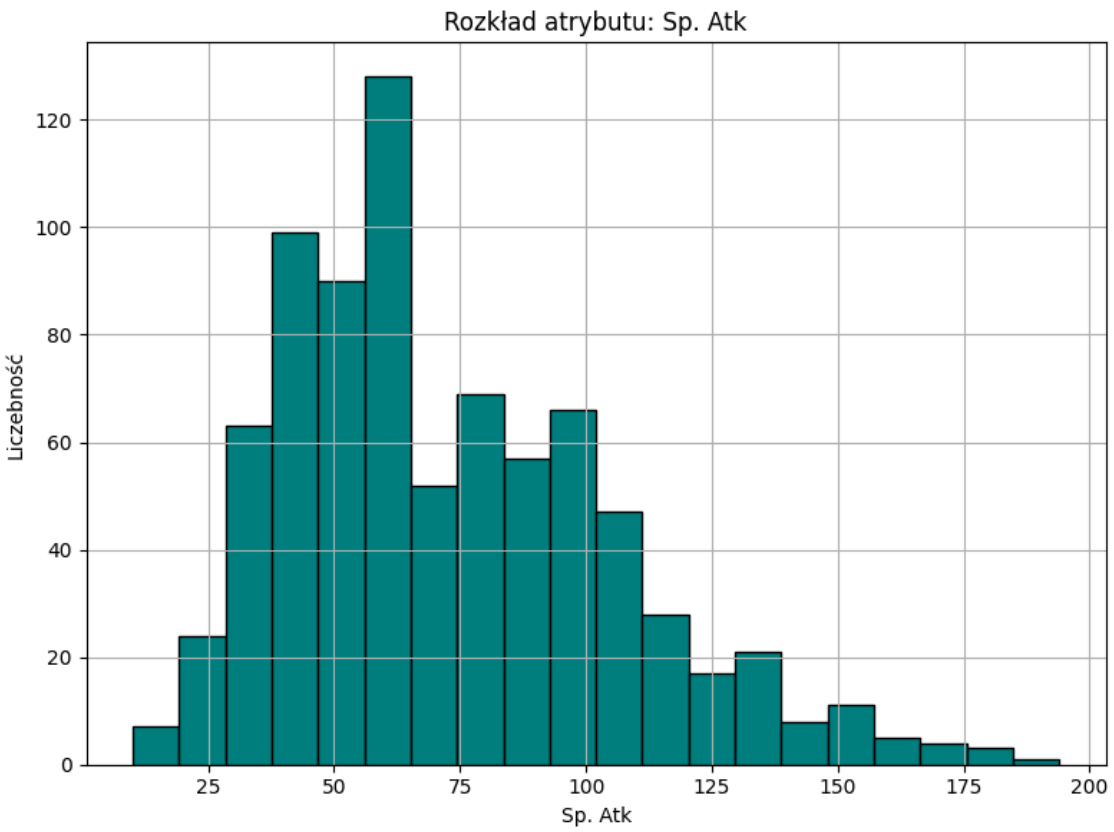
Sp. Def	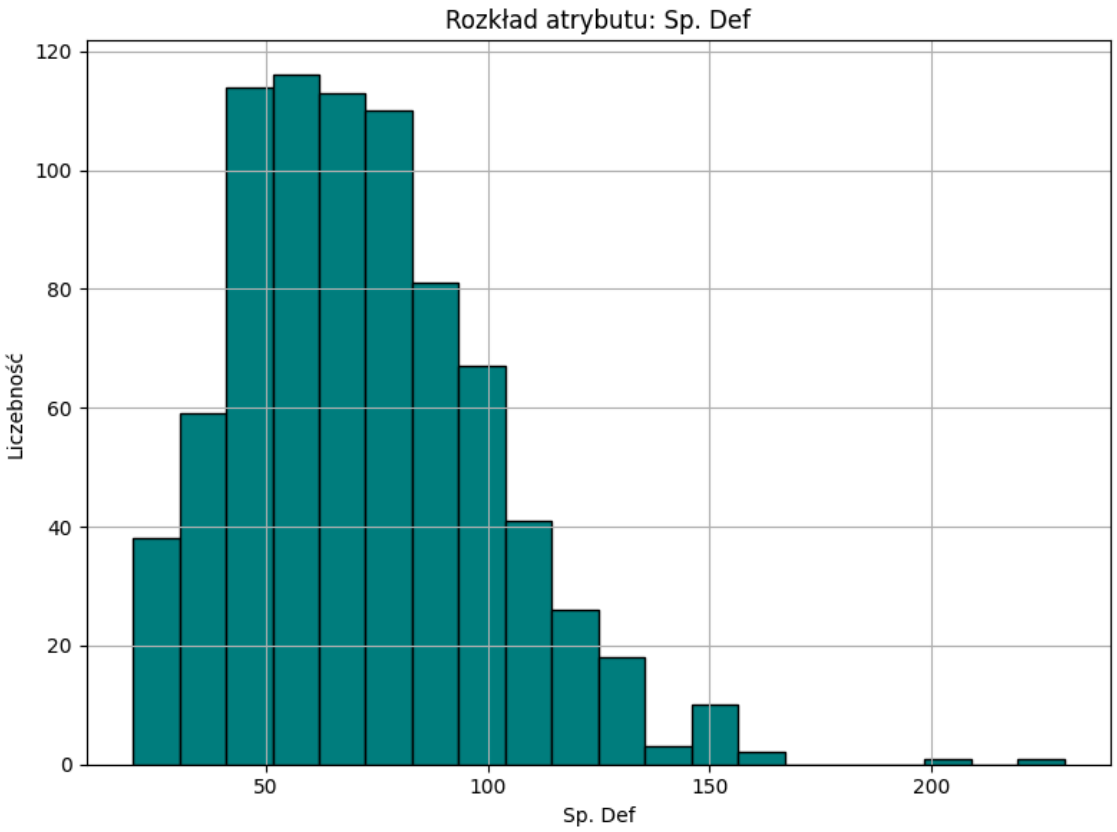

Atrybut	Histogram
Speed	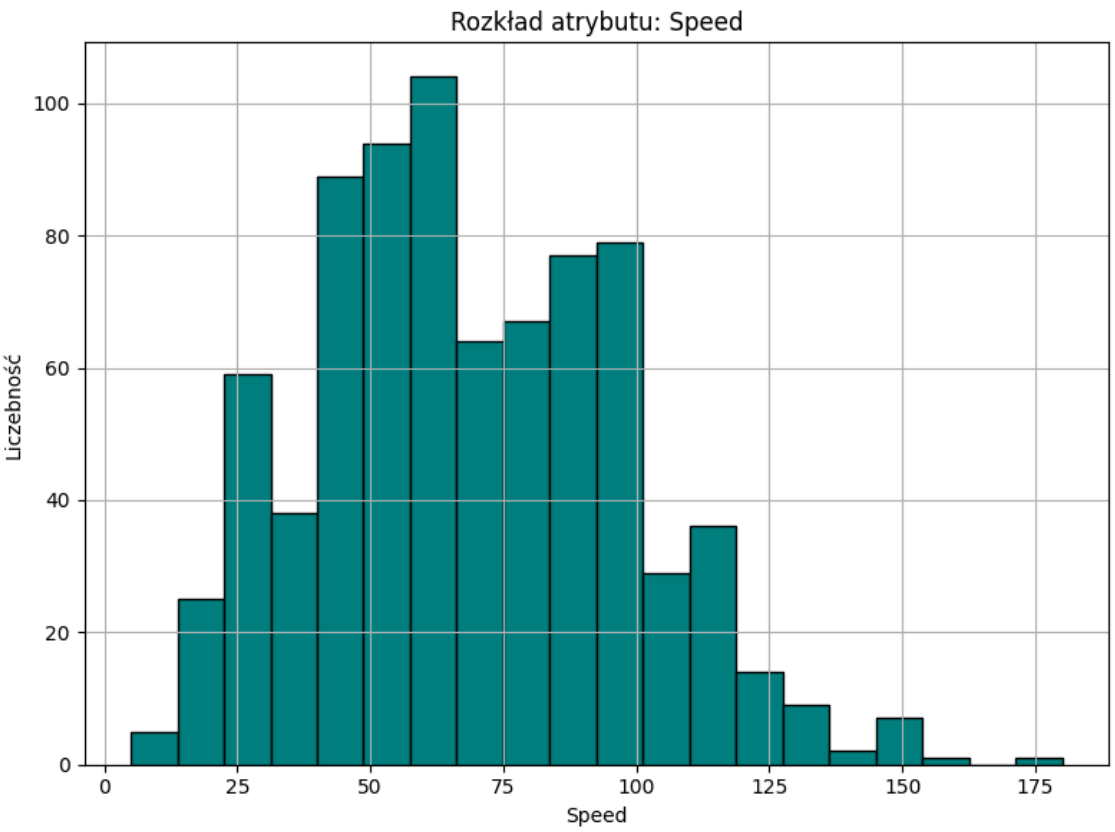
Generation	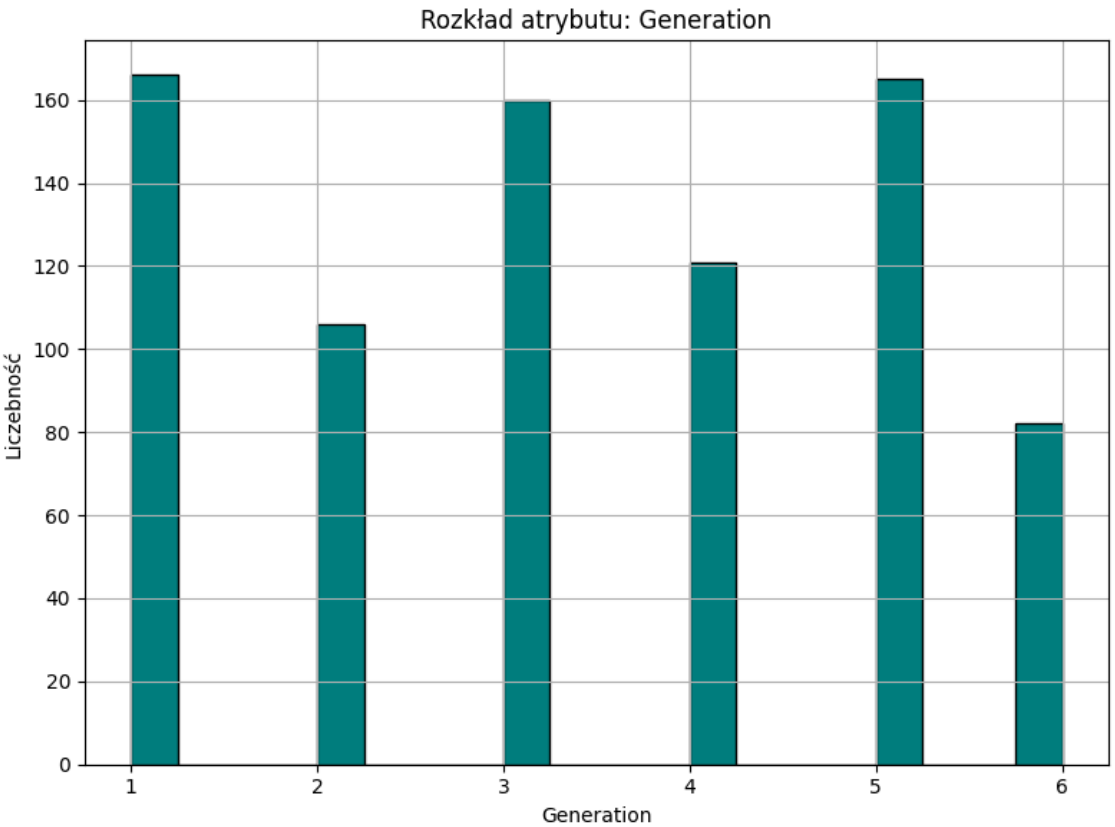

Atrybut	Histogram
Type 1	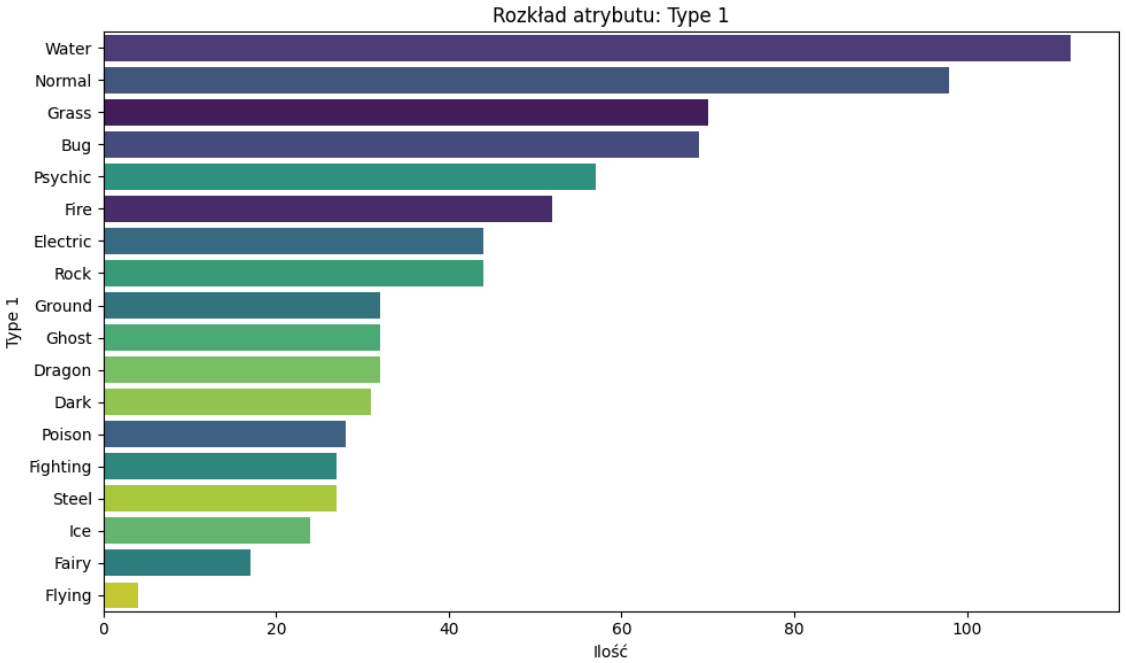
Type 2	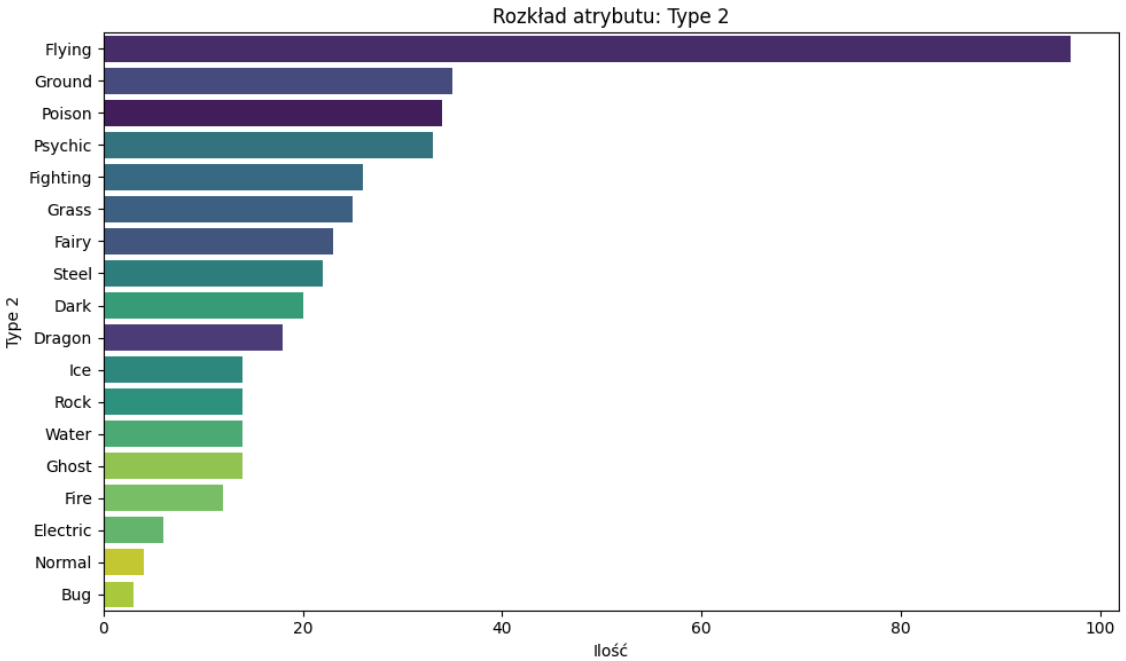

Atrybut	Histogram
Legendary	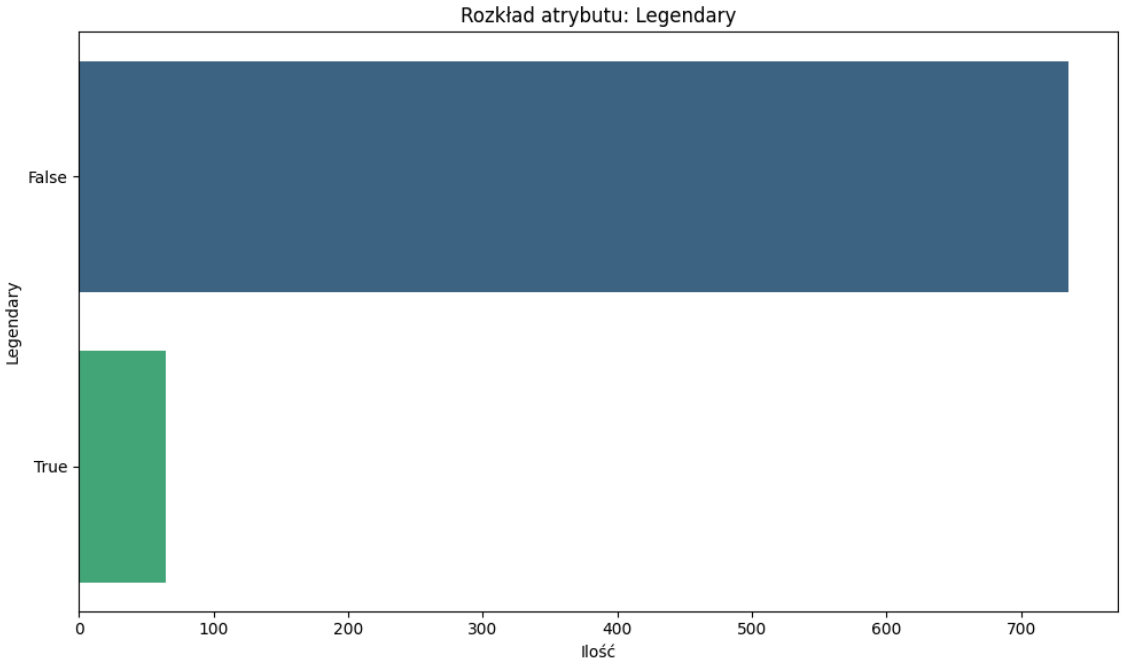

Wnioski:

- W przypadku zmiennej celu (zwycięstwo pierwszego lub drugiego Pokemona wynikające ze zbioru walk), klasy są bardzo dobrze zbalansowane ze względu na specyfikę konstrukcji turnieju. Równy rozkład ułatwi proces dalszych analiz i trenowania modelu klasyfikacji.
- Rozkłady wszystkich analizowanych atrybutów numerycznych związanych ze statystykami (`HP`, `Attack`, `Defense`, `Sp. Atk`, `Sp. Def`, `Speed`) wydają się nie być w pełni normalne. Najczęściej mamy do czynienia z rozkładem prawoskośnym - rozkład jest przesunięty w lewo a dłuższy ogon znajduje się po prawej stronie wykresu.
- Najsilniejsze Pokemony (szczególnie te z flagą `Legendary`) odznaczają się unikalnie wysokimi atrybutami, ponieważ pełnią rolę tzw. "bossów" w uniwersum. W związku z czym wysokie, nieliczne wartości (ogon rozkładu) wymienionych atrybutów bojowych mogą stanowić bardzo silny wskaźnik sugerujący Pokemona, który częściej będzie zwyciężał (status `Winner`).
- W przypadku atrybutów kategorycznych, takich jak `Type 1`, możemy dostrzec silne skupisko w lewej stronie rozkładu – dominują głównie żywioły Water oraz Normal. Pozostałe klasy (np. Flying) występują sporadycznie początkowych wartościach. Różnorodność typów w ogonie rozkładu wpłynie na to, w jaki sposób model będzie brał pod uwagę macierze przewag żywiołów (np. Ogień wygrywa z Trawą).

Sprawdzenie testem statystycznym - dodatkowo Określenie, czy rozkład atrybutu jest normalny czy nie po prostu na niego patrząc najczęściej spełnia swoje zadanie. Jednakże w razie wątpliwości i w celu bardziej rzetelnego określenia normalności rozkładu można zastosować test statystyczny Shapiro-Wilka. Hipotezą zerowa tego testu brzmi: dana próba pochodzi z populacji o rozkładzie normalnym. Po obliczeniu wartości p należy ją porównać z przyjmowanym progiem (najczęściej 0,05). Jeżeli wartość p jest większa od 0,05 oznacza to, że dane pasują do hipotezy zerowej - możemy uznać rozkład danego atrybutu za normalny. Natomiast, jeżeli wartość p jest mniejsza od 0,05 to należy odrzucić hipotezę zerową - uznajemy, że rozkład atrybutu nie jest normalny. Wartość p można rozumieć jako prawdopodobieństwo uzyskania takiego wyniku, przy założeniu, że hipoteza zerowa jest prawdziwa. Na przykład: jeśli p jest małe (np. mniejsze niż 0,05), to istnieje małe prawdopodobieństwo, że takie dane zostałyby zaobserwowane, jeśli rozkład byłby normalny – co może sugerować, że rozkład nie jest normalny.

Atrybut	Wartość p dla testu Shapiro-Wilka
HP	1,15e-20
Attack	2,47e-09
Defense	9,92e-18
Sp. Atk	4,67e-14
Sp. Def	8,25e-14
Speed	1,31e-07
Generation	8,71e-22

Wnioski Na podstawie powyższej tabeli możemy powiedzieć z dużą pewnością, że wszystkie atrybuty numeryczne nie mają rozkładu normalnego (wartość p jest znacznie mniejsza od progu 0,05). Dodatkowo widać, że atrybuty `Speed` oraz `Attack` mają jedne z najwyższych wartości p, lecz wciąż zdecydowanie mniejsze od 0,05.

2. **Korelacje pomiędzy wartościami atrybutów**

   W celu obliczenia korelacji z wynikiem walki zamieniono zwycięstwo pierwszego Pokemona (zmienna celu `First_won`) na 1 i przegraną na 0. W związku z faktem, że żaden atrybut nie miał rozkładu normalnego stosuję korelację Spearmana.

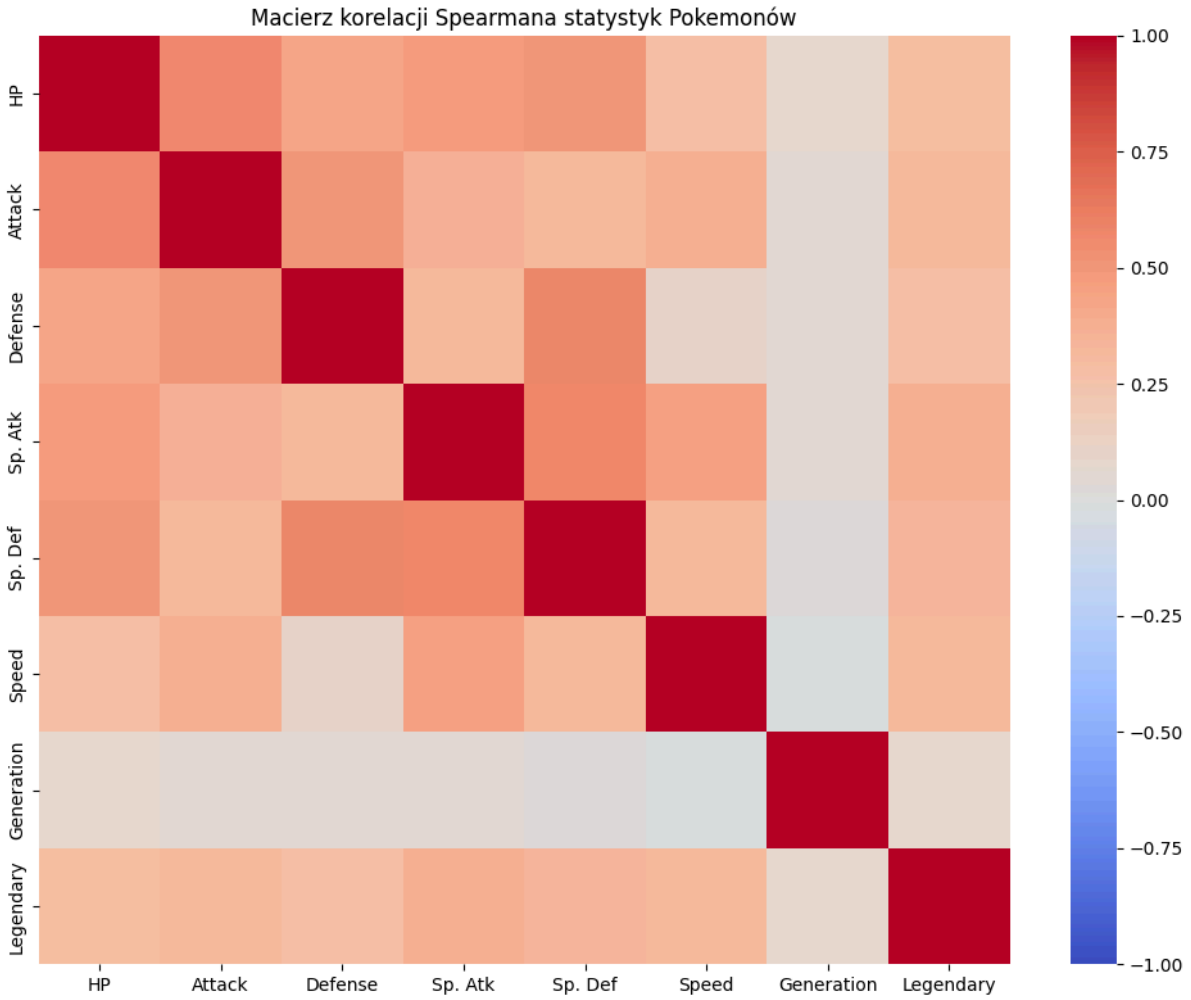
Macierz korelacji Spearmana statystyk Pokemonów
HP
Attack
Defense
Sp. Atk
Sp. Def
Speed
Generation
Legendary
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00

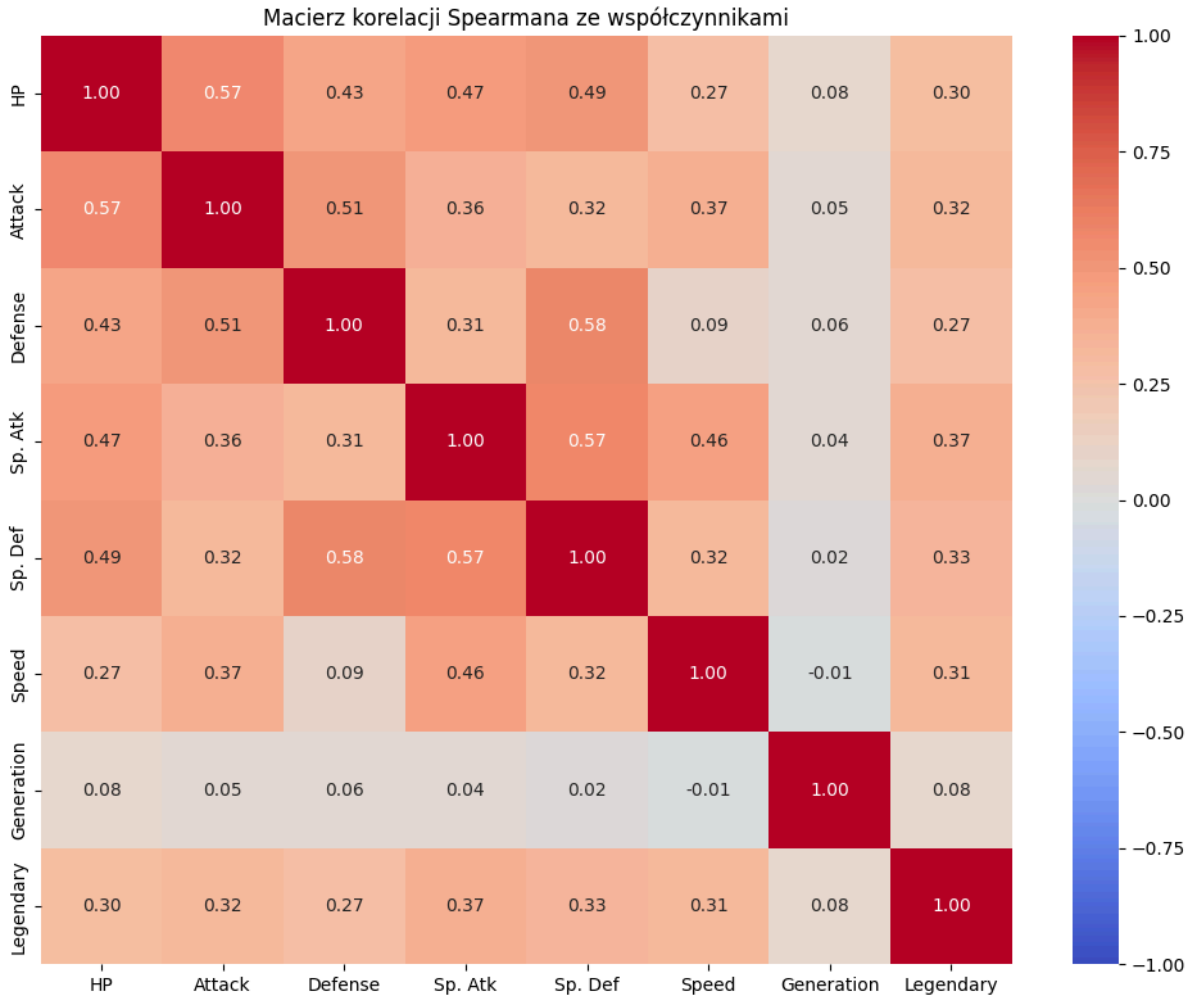

Wnioski:

- Widoczne są grupy atrybutów z silną korelacją między sobą w obrębie podstawowych statystyk bojowych: `Attack`, `Defense`, `Sp. Atk`, `Sp. Def` oraz `HP`. Wszystkie te atrybuty odnoszą się do ogólnej siły Pokemona, więc ich wzajemna, silna korelacja jest naturalna. Zależność ta staje się jeszcze bardziej zauważalna w przypadku atrybutu `Legendary` – legendarne Pokemony charakteryzują się z reguły najwyższymi wartościami wszystkich bazowych statystyk w grze. Mniejszą korelację możemy zaobserwować np. z atrybutem pokolenia (`Generation`), co oznacza, że wraz z wychodzeniem nowszych edycji parametry bojowe pozostają relatywnie wyrównane i nie są znacząco podbijane pod zjawisko "power creepingu". Sama korelacja dodatnia pomiędzy atrybutami uderzeń dystansowych (`Sp. Atk`, `Sp. Def`) a standardowymi fizycznymi uderzeniami (`Attack`, `Defense`) może wynikać z pojawiania się na nowszych etapach gry coraz większej ilości wyewoluowanych form, co po prostu podnosi wszystkie te wartości naraz.

Korelacja z atrybutem wygranej

W celu wyznaczenia konkretnych atrybutów determinujących zwycięstwo na potrzeby modelu predykcyjnego zestawiono różnice w parametrach obu przeciwników (`Diff_...`) i obliczono ich relację ze zmienną `First_won` (1 dla zwycięstwa, 0 dla porażki w walce).

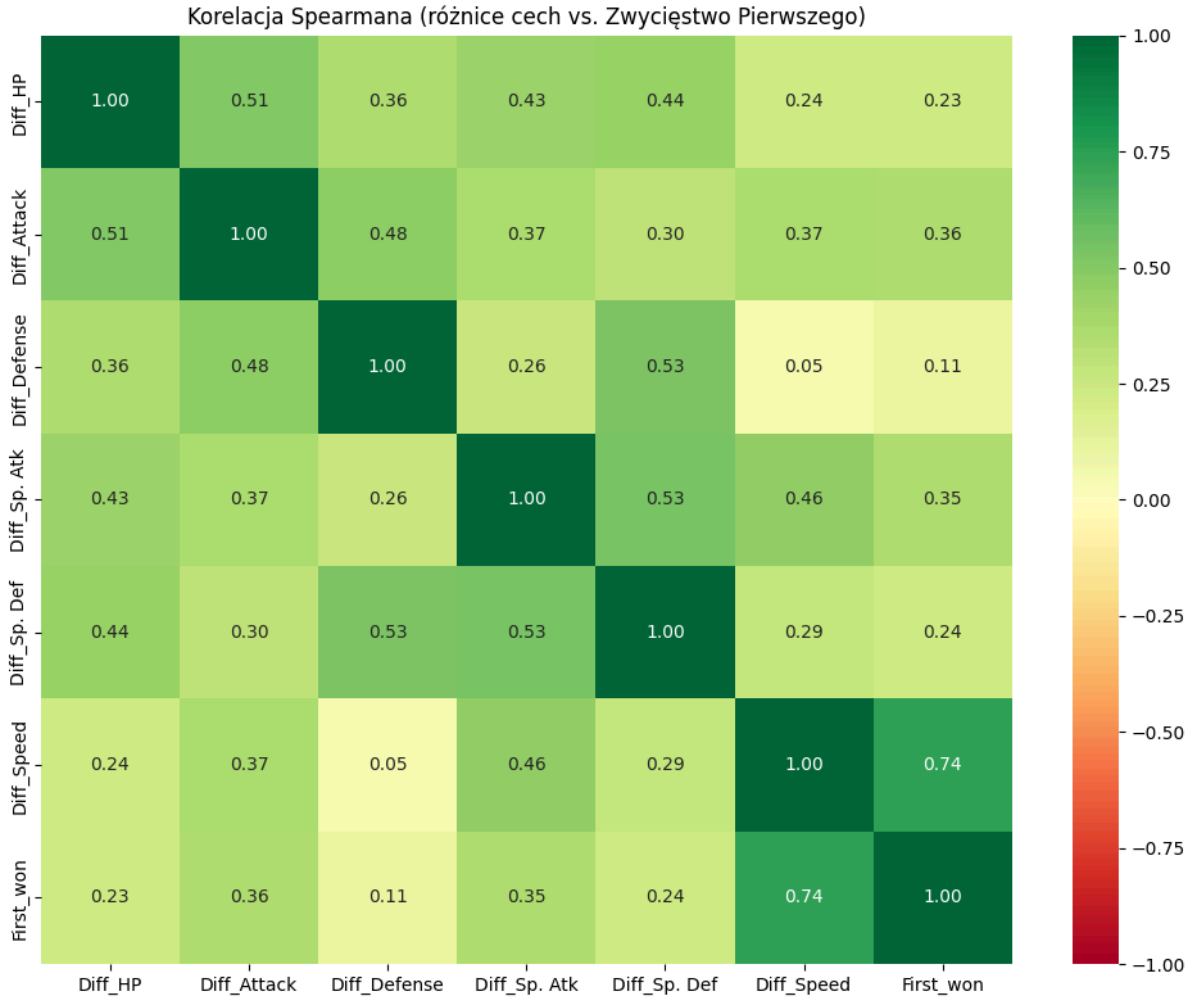

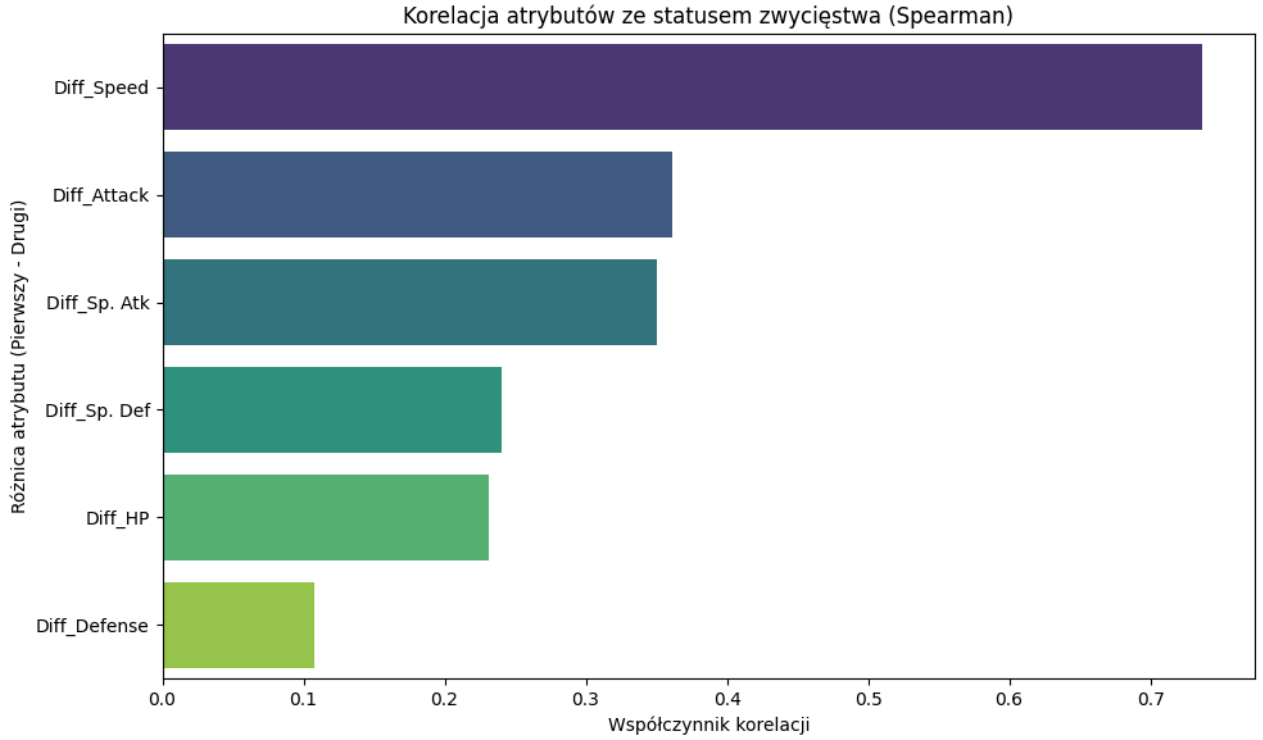

Wnioski:

- W przypadku zmiennej celu wyznaczającej zwycięstwo przeważnie wszystkie analizowane, różnicowe atrybuty numeryczne wykazują dodatnią korelację. W żaden sposób nie wpływają przeciwnie (nie zmniejszają szans).

    - Różnica w szybkości (`Diff_Speed`) wyróżnia się jako atrybut o zdecydowanie najwyższej korelacji (współczynnik powyżej 0.7). Wynika to z mechaniki walki, w której szybszy Pokemon atakuje jako pierwszy, co daje mu ogromną przewagę taktyczną już na samym starcie.
    - Atrybuty ofensywne (`Diff_Attack`, `Diff_Sp. Atk`) stanowią kolejną grupę ze stosunkowo silną korelacją (oscylującą w okolicy 0.5). Silny atak zadany zaraz po zapewniającej inicjatywę różnicy szybkości przekłada się bezpośrednio na dominację w walce.
    - Atrybuty związane typowo ze statystykami wytrzymałości i obrony (`Diff_HP`, `Diff_Defense`, `Diff_Sp. Def`) wykazują zauważalnie mniejszą korelację z wygraną (np. 0.34 dla `HP`). Oznacza to, że przewaga ofensywa na ogół lepiej determinuje ostateczny wynik starcia niż wybór Pokemona skupionego wyłącznie na przyjmowaniu obrażeń i wysokim zdrowiu.

3. **Wstępne ustalenia dotyczące zawartości zbioru**

    - Posiadanie dwóch różniących się typów plików zmusza nas do wykonania połączeń tabel (*join/merge*) za pomocą identyfikatorów Pokemona. Tylko zestawienie statystyk z wynikiem walki pozwoli na budowę odpowiedniego modelu.

Uwagi na temat jakości danych

- **Dane brakujące:** Zidentyfikowano **1 brak nazwę dla Pokemona** (`Name` ma 1 Null) oraz **386 brakujących wartości** dla `Type 2`. Braki w `Type 2` wynikają ze specyfiki świata Pokemon (nie wszystkie posiadają typ drugorzędny), przez co zamiast je usuwać, warto uzupełnić je etykietą `None` (lub `Brak`). W `combats.csv` nie odnotowano braków.
- **Dane niespójne:** Ze względu na to, że dane w bazowym pliku *pokemon.csv* określają cyfrowe wartości generowane przez twórców gier wideo, niespójność można weryfikować głównie za pomocą powiązań między założeniami mechaniki. Jednakże ze względu na wysokie korelacje pomiędzy atrybutami dotyczącymi siły potworów (np. wzajemnie zależny wzrost `Attack`, `Defense`, `Sp. Atk`, `Sp. Def` wraz z flagą rzadkości `Legendary`), możemy założyć, że dane są spójne. Dana wysoka korelacja nie wyklucza 100% ukrytych błędów merytorycznych, jednakże powiązania tych wskaźników siły wydają się w oczywisty sposób logiczne.
- **Dane niezrozumiałe:** W ogólności dane są zrozumiałe na dość intuicyjnym poziomie. Dla niektórych czytelników rodzą się pytania o ramy przeliczania logiki obciążeń w grze - na przykład brak dokładnych wzorów "custom algorytmu turniejowego" odpowiadającego z udostępnione wyniki w pliku *combats*. Nie wiemy chociażby, z jakim algorytmicznym współczynnikiem wzmacniającym kalkulowane są uderzenia w słabość przeciwnika uwzględniając skrzyżowanie `Type 1` i `Type 2`. Jednakże na potrzeby tego projektu takie intuicyjne zrozumienie podstaw atrybutów wydaje się być wystarczające i model powinien dać radę samodzielnie dojść do interesujących i dobrych wniosków predykcyjnych.
- **Punkty oddalone:** Analizując punkty oddalone można dojść do wniosku, że dane są bardzo dobrej jakości. Średnia liczba punktów oddalonych względem atrybutów numerycznych wynosi ok. 10 (metodą rozstępu ćwiartkowego IQR), co stanowi zaledwie ok. 1,2% wszystkich dostępnych 800 danych wejściowych w zbiorze Pokemon. Atrybutami o największej liczbie punktów oddalonych są atrybuty `HP` (19 punktów oddalonych: ok. 2,4% danych zbioru jednostek), `Defense` (13 punktów oddalonych: ok. 1,6%) oraz `Sp. Atk` (10 punktów: ok. 1,2%). Odbiegające wartości stanowią charakterystykę wyjątkowych bosów (Legendary), w związku z czym absolutnie nie stanowią błędu, a jedynie wzmacniają siłę przewidywań przyszłego klasyfikatora.

Atrybut	Wykres pudełkowy	Wartości
HP	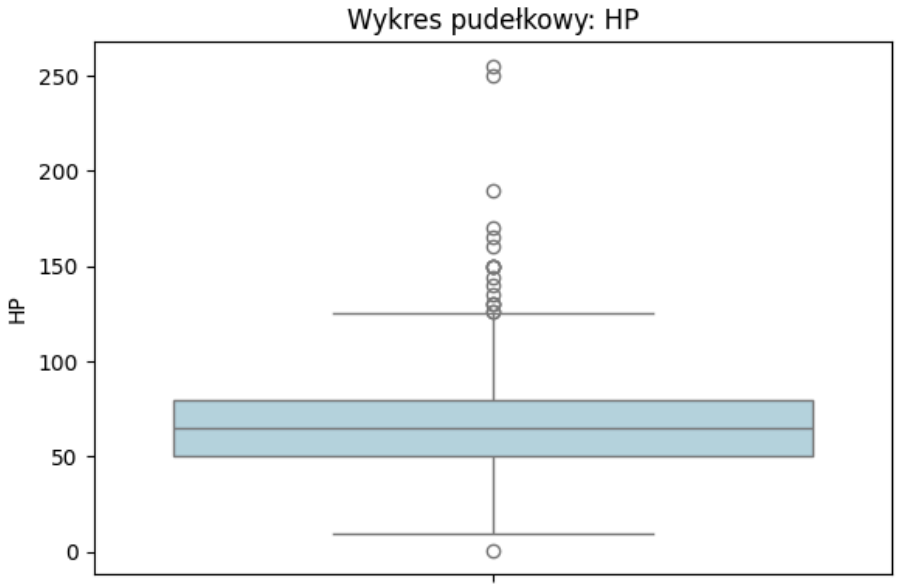	Mediana: 65.00 Przedział wartości występujących najczęściej: [10.00; 125.00] Liczba punktów oddalonych: 19
Attack	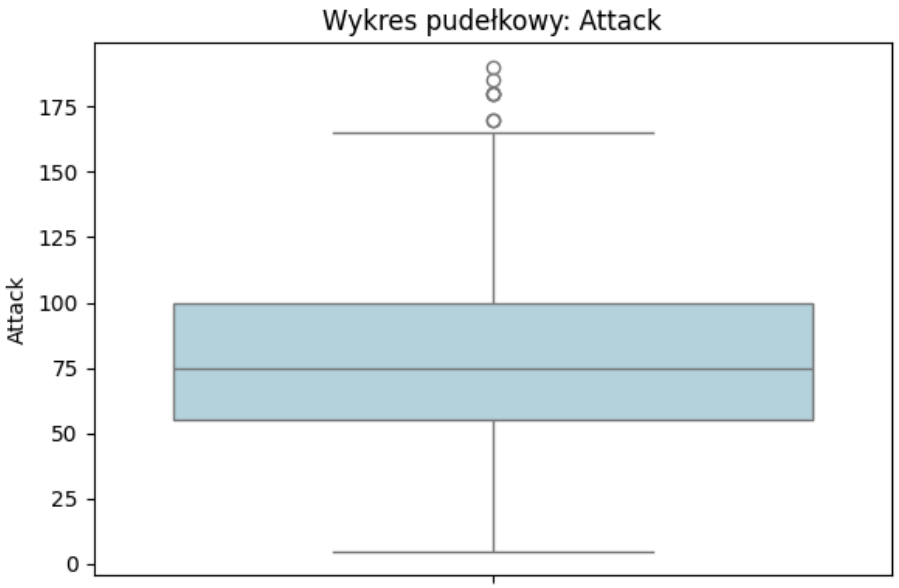	Mediana: 75.00 Przedział wartości występujących najczęściej: [5.00; 165.00] Liczba punktów oddalonych: 7
Defense	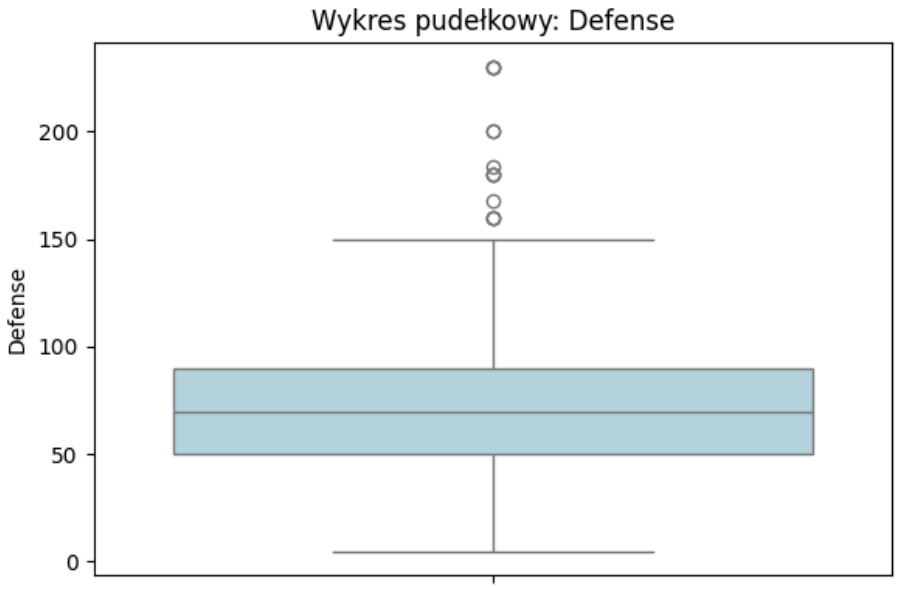	Mediana: 70.00 Przedział wartości występujących najczęściej: [5.00; 150.00] Liczba punktów oddalonych: 13

Atrybut	Wykres pudełkowy	Wartości
Sp. Atk	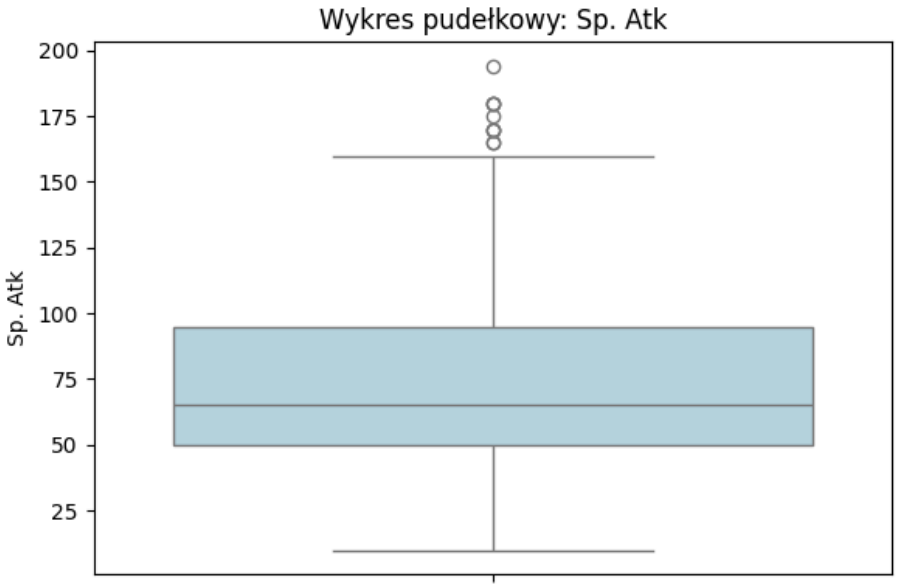	Mediana: 65.00 Przedział wartości występujących najczęściej: [10.00; 160.00] Liczba punktów oddalonych: 10
Sp. Def	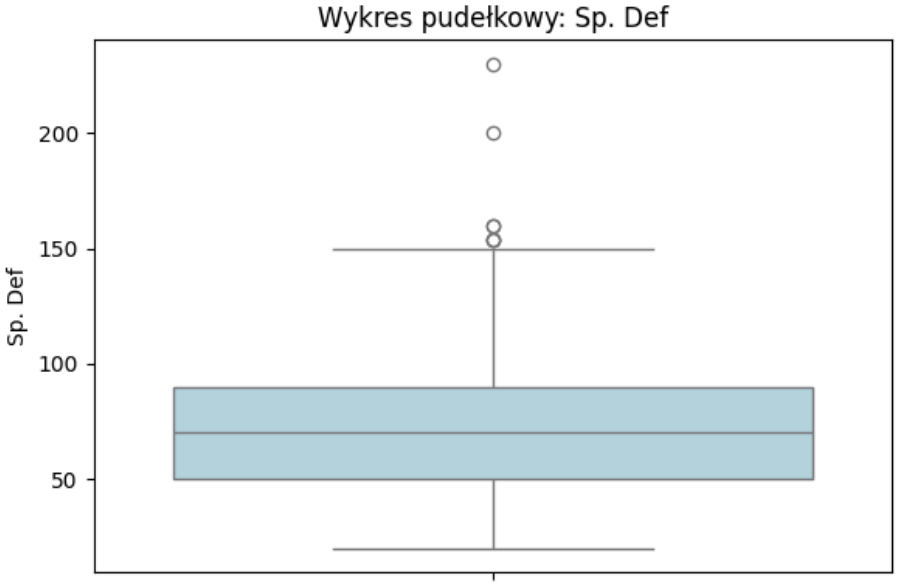	Mediana: 70.00 Przedział wartości występujących najczęściej: [20.00; 150.00] Liczba punktów oddalonych: 7
Speed	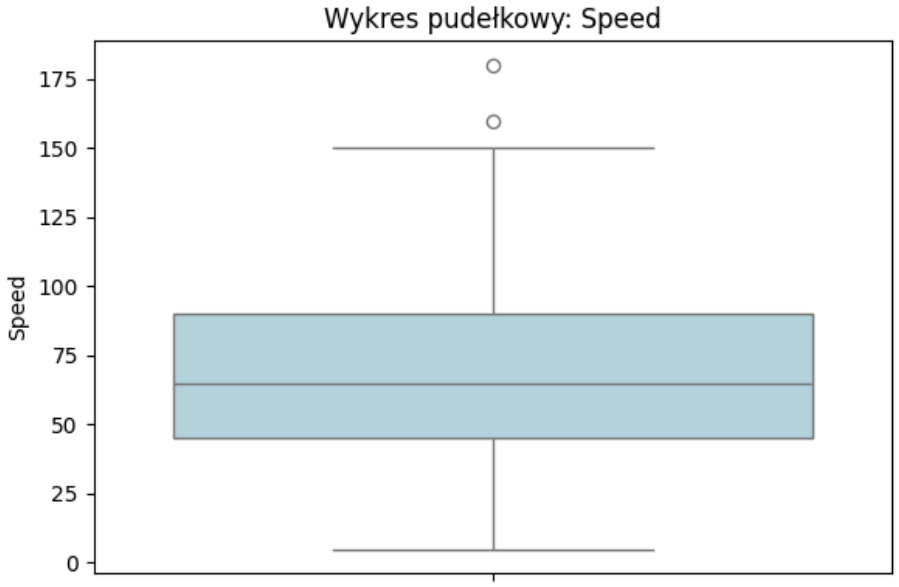	Mediana: 65.00 Przedział wartości występujących najczęściej: [5.00; 150.00] Liczba punktów oddalonych: 2

Podsumowanie

Na początku przeprowadzono analizę rozkładów, z której wynika, że atrybuty numeryczne nie mają rozkładów normalnych, a klasy rozkładu w turniejach cechują się zmiennością. W związku z tym zastosowano metodę Spearmana do analizy korelacji. Z analizy korelacji wynika, że występują grupy atrybutów silnie ze sobą skorelowane – pierwsza grupa: `Attack`, `Defense`, `Sp. Atk`, `Sp. Def`, druga grupa obejmuje powiązanie `HP` z bazowymi statystykami. Ze względu na dużą korelację danych atrybutów, przekazują one podobną informację (definiując ogólną siłę Pokemona związaną m.in. z ewolucją czy przynależnością do klasy `Legendary`), co może być redundantne dla modelu.

Następnie obliczono korelację względem atrybutu celu (`First_won`). Atrybutami, które najsilniej korelują z wynikiem starcia są w kolejności: `Diff_Speed`, `Diff_Attack`, `Diff_Sp. Atk`, `Diff_Sp. Def`, `Diff_HP` i `Diff_Defense`. Są to przeważnie atrybuty należące do grup silnie skorelowanych zmiennych bojowych. W związku z czym w fazie modelowania można rozważyć usunięcie niektórych atrybutów pozostawiając tylko kluczowy w grupie, przykładowo biorąc pod uwagę wartości korelacji ze zmienną zwycięstwa – wystarczający może okazać się parametr `Diff_Speed` w asyście `Diff_Attack`.

Dodatkowo większość atrybutów (zwłaszcza różnicowych) ma korelację dodatnią z wynikiem bitwy, z czego wynika, że ich wyższe wartości częściej występują wśród przypadków ostatecznego zwycięstwa (ponieważ do obliczania korelacji wygrana reprezentowana przez pierwszego osobnika została zamieniona na 1, a dla drugiego na 0). Zgadza się to z mechaniką gry, w której przewaga szybkości i siły ataku pozwala na zadanie kluczowych obrażeń, zanim wolniejszy i słabszy przeciwnik zdąży zareagować.

Następnie dokonano oceny jakości danych. Głównym mankamentem danych jest brak dokumentacji udostępnionego "silnika" symulującego wyniki walk podanych w zbiorze – nie podano wzorów dokładnego wyznaczania obrażeń oraz ewentualnych wskaźników losowości czy mnożników żywiołów. Dlatego wyjściowo ciężko jest ze stuprocentową pewnością ocenić, czy występowanie każdego punktu w pełni ma sens, czy też nie (bez znania całego kodu symulacji). Jednakże ze względu na silną dodatnią korelację ze statusem zwycięzcy, występowanie tzw. outlierów w głównych statystykach zawsze świadczy o dużej przewadze legendarnego Pokemona, a zatem jest wysoce przydatne dla modelu. W związku z czym najlepszą decyzją docelową byłoby ścisłe pozostawienie wartości odstających w zbiorze bez ingerencji.

Biorąc pod uwagę stosunkowo dobrą jakość danych, cel eksploracji jest możliwy do spełnienia.